

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Tổng Trọng Tâm

NGHIÊN CỨU MÔ HÌNH
DỊCH MÁY HAI CHIỀU GIỮA
CHỮ HÁN NÔM VÀ CHỮ QUỐC NGỮ

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH TRÍ TUỆ NHÂN TẠO

Tp. Hồ Chí Minh, tháng 7/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Tổng Trọng Tâm - 22120322

NGHIÊN CỨU MÔ HÌNH
DỊCH MÁY HAI CHIỀU GIỮA
CHỮ HÁN NÔM VÀ CHỮ QUỐC NGỮ

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH TRÍ TUỆ NHÂN TẠO

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Đinh Điền

TS. Nguyễn Hồng Bửu Long

Tp. Hồ Chí Minh, tháng 7/2026

Lời cam đoan

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi. Các số liệu và kết quả nghiên cứu trong khóa luận này là trung thực và không trùng lặp với các đề tài khác.

Lời cảm ơn

Khóa luận này đánh dấu chặng cuối trong bốn năm học tập của tôi tại trường. Quá trình thực hiện đề tài giúp tôi học thêm về chuyên môn, nhưng cũng buộc tôi rèn luyện cách làm việc có kế hoạch, kiểm tra giả thiết và nhìn nhận thẳng thắn những điều một kết quả thực nghiệm chưa thể kết luận.

Trong hơn sáu tháng thực hiện khóa luận, tôi đã nhận được sự hướng dẫn và hỗ trợ từ thầy cô, bạn bè và gia đình. Những giúp đỡ đó cho phép tôi theo đuổi đề tài đến cùng và hoàn thiện bản thảo này.

Trước hết, tôi xin gửi lời cảm ơn chân thành đến PGS. TS. Đinh Điền, người đã tạo điều kiện để tôi thực hiện đề tài, đồng thời cung cấp nguồn dữ liệu quý giá phục vụ cho quá trình nghiên cứu. Thầy cũng đã giới thiệu và truyền đạt cho tôi những kiến thức nền tảng về chữ Hán Nôm, một di sản chữ viết quan trọng của dân tộc, giúp tôi hiểu rõ hơn về đặc điểm ngôn ngữ, cấu trúc văn bản cũng như những thách thức trong việc xử lý và số hóa loại hình dữ liệu này. Những định hướng của thầy trong việc khai thác ngữ liệu, cách tiếp cận bài toán và các góp ý chuyên môn đã giúp tôi xây dựng được nền tảng vững chắc để triển khai và hoàn thiện khóa luận.

Tiếp theo, tôi xin trân trọng cảm ơn TS. Nguyễn Hồng Bửu Long, người đã hướng dẫn tôi về các kiến thức liên quan đến trí tuệ nhân tạo, đặc biệt là các phương pháp trong xử lý ngôn ngữ tự nhiên và mô hình dịch máy. Thầy đã giúp tôi định hướng cách tiếp cận bài toán từ góc độ kỹ thuật, cung cấp những kiến thức về mô hình ngôn ngữ lớn, phương pháp huấn luyện và đánh giá mô hình, cũng như hỗ trợ tôi trong quá trình xây dựng

và cải tiến hệ thống. Những trao đổi chuyên môn, góp ý chi tiết và sự hỗ trợ tận tình của thầy đã giúp tôi vượt qua nhiều khó khăn trong quá trình thực hiện khóa luận và hoàn thiện công trình nghiên cứu này.

Tôi xin chân thành cảm ơn các thầy, cô Trường Đại học Khoa học Tự nhiên đã giảng dạy và truyền đạt cho tôi những kiến thức quý báu trong suốt bốn năm học tập tại trường. Những nền tảng học thuật mà thầy cô cung cấp là cơ sở quan trọng giúp tôi thực hiện và hoàn thành khóa luận này.

Cuối cùng, tôi xin bày tỏ lòng biết ơn sâu sắc đến gia đình, đặc biệt là mẹ tôi, người đã luôn là điểm tựa vững chắc và là nguồn động lực tinh thần to lớn giúp tôi vượt qua những giai đoạn khó khăn nhất. Những lời dạy về sự kiên nhẫn và tâm huyết trong công việc luôn là kim chỉ nam để tôi tiếp tục theo đuổi đam mê nghiên cứu. Tôi cũng xin gửi lời cảm ơn đến những người bạn đã luôn đồng hành, động viên tôi trong những thời khắc căng thẳng, giúp tôi giữ vững tinh thần và tiếp tục bước đi trên hành trình của mình.



fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHÓA LUẬN TỐT NGHIỆP

NGHIÊN CỨU MÔ HÌNH DỊCH MÁY HAI CHIỀU GIỮA CHỮ HÁN NÔM VÀ CHỮ QUỐC NGỮ

*(A Study of Approaches to Bidirectional Machine Translation
between Sino-Nôm and the Vietnamese National Script)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS. Đinh Điền (Khoa Công nghệ Thông tin)
- TS. Nguyễn Hồng Bửu Long (Khoa Công nghệ Thông tin)

Sinh viên thực hiện:

1. Tổng Trọng Tâm (MSSV: 22120322)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 1/2026 đến 7/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hán Nôm là hệ chữ viết cổ của người Việt, bao gồm chữ Hán vay mượn từ Trung Hoa và chữ Nôm do người Việt sáng tạo dựa trên chất liệu chữ Hán [1]. Trong nhiều thế kỷ, hệ chữ này được sử dụng để ghi chép các tài liệu thuộc nhiều lĩnh vực như văn học, lịch sử, y học, địa lý,... tạo nên một kho tàng tri thức có giá trị đặc biệt đối với văn hóa và lịch sử dân tộc. Tuy nhiên, ngày nay chỉ còn một bộ phận nhỏ có thể tiếp cận trực tiếp các văn bản Hán Nôm, chủ yếu là các nhà nghiên cứu chuyên ngành, do sự khan hiếm tài liệu học tập cũng như độ phức tạp vốn có của hệ chữ viết này.

Để bảo tồn, số hóa và khai thác kho tư liệu Hán Nôm trong bối cảnh công nghệ thông tin phát triển, nhiều nghiên cứu đã được thực hiện về bài toán chuyển tự giữa chữ Hán/Nôm và chữ Quốc ngữ. Các hướng tiếp cận trước đây chủ yếu dựa trên dịch máy thống kê (SMT) [2, 3], trong khi các nghiên cứu gần đây bắt đầu áp dụng dịch máy nơ ron (NMT) [4]. Mục tiêu của bài toán là chuyển đổi giữa chữ Hán/Nôm và chữ Quốc ngữ theo cách bảo toàn cách đọc của văn bản, phục vụ cả nhu cầu đọc hiểu tài liệu cổ lẫn hỗ trợ số hóa và phục dựng văn bản.

Chữ Hán	Chuyển tự Quốc ngữ
“南國山河南帝居”	“Nam quốc sơn hà Nam đế cư”
“截然定分在天書”	“Tiệt nhiên định phận tại thiên thư”
“如何逆虜來侵犯”	“Như hà nghịch lỗ lai xâm phạm”
“汝等行看取敗虛”	“Nhữ đẳng hành khan thủ bại hư”

Bảng 1: Ví dụ chuyển tự bài thơ “Nam quốc sơn hà” (Lý Thường Kiệt) [5]

Mặc dù đã đạt được nhiều kết quả khả quan, các nghiên cứu hiện nay vẫn còn một số hạn chế. Phần lớn các phương pháp được xây dựng theo hướng dịch máy tổng quát, trong khi bài toán chuyển tự có đặc trưng căn chỉnh gần một đối một giữa ký tự nguồn và ký tự hoặc âm tiết đích. Bên cạnh đó, hiện tượng đa trị của chữ Hán và chữ Nôm, khi một ký tự có thể tương ứng với nhiều cách đọc hoặc

nhiều ký tự đích khác nhau tùy theo ngữ cảnh, vẫn là một thách thức lớn. Ngoài ra, hầu hết các công trình đều chỉ tập trung vào một chiều chuyển tự, chưa khai thác được tính đối ngẫu giữa hai chiều Hán/Nôm $\leftrightarrow$ Quốc ngữ trong một mô hình thống nhất.

Xuất phát từ những hạn chế trên, đề tài tập trung nghiên cứu bài toán chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ bằng mô hình học sâu. Cụ thể, đề tài khai thác bộ mã hóa hai chiều BERT được huấn luyện từ đầu trên từ vựng thống nhất của cả hai hệ chữ, kết hợp cơ chế ràng buộc tập ứng viên để thu hẹp không gian dự đoán từ toàn bộ từ vựng xuống tập các ứng viên hợp lệ tại từng vị trí. Trên nền tảng đó, đề tài đề xuất các phương pháp mới hướng tới nâng cao chất lượng chuyển tự đồng thời vẫn bảo đảm tính nhất quán về mặt ngôn ngữ học.

2.2 Mục tiêu đề tài

Về mặt khoa học, đề tài hướng đến việc nghiên cứu một hướng tiếp cận mới cho bài toán chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ. Cụ thể, đề tài khai thác đặc trưng căn chỉnh gần một đối một của bài toán để kết hợp bộ mã hóa hai chiều BERT với cơ chế ràng buộc tập ứng viên, qua đó thu hẹp không gian dự đoán và nâng cao khả năng xử lý hiện tượng đa trị của chữ Hán và chữ Nôm.

Về mặt thực tiễn, kết quả của đề tài góp phần xây dựng công cụ hỗ trợ chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ, phục vụ quá trình số hóa, bảo tồn và khai thác kho tư liệu Hán Nôm. Đồng thời, phương pháp đề xuất có thể được mở rộng cho các bài toán chuyển tự khác có đặc trưng căn chỉnh gần một đối một giữa chuỗi nguồn và chuỗi đích.

2.3 Phạm vi của đề tài

Về lý thuyết, đề tài nghiên cứu và ứng dụng các mô hình học sâu vào bài toán chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ. Trọng tâm là kiến trúc bộ mã hóa BERT được huấn luyện từ đầu kết hợp với cơ chế ràng buộc tập ứng viên và hai chiến lược giải mã tương ứng với hai phương pháp đề xuất.

Về đối tượng nghiên cứu, đề tài tập trung vào văn bản chữ Hán và chữ Nôm của Việt Nam cùng văn bản chữ Quốc ngữ tương ứng, bao quát cả hai chiều chuyển tự Hán/Nôm $\leftrightarrow$ Quốc ngữ.

Về nguồn ngữ liệu, đề tài sử dụng kho ngữ liệu song song và các nguồn tự điển do Trung tâm Ngôn ngữ học Tính toán, Trường Đại học Khoa học Tự nhiên cung cấp để xây dựng tập dữ liệu huấn luyện, từ vựng thống nhất và tập ứng viên cho từng ký tự nguồn.

Về mô hình, đề tài nghiên cứu các phương pháp chuyển tự hai chiều dựa trên bộ mã hóa BERT kết hợp cơ chế ràng buộc tập ứng viên.

2.4 Cách tiếp cận dự kiến

Đề tài tiếp cận bài toán chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ theo hướng học sâu, khai thác đặc trưng căn chỉnh gần một đối một của bài toán để thu hẹp không gian dự đoán tại mỗi vị trí về tập ứng viên hợp lệ thay vì toàn bộ từ vựng đích.

Mô hình sử dụng bộ mã hóa hai chiều BERT được huấn luyện từ đầu trên một từ vựng thống nhất bao phủ đồng thời chữ Hán/Nôm và chữ Quốc ngữ. Trên nền tảng bộ mã hóa này, đề tài đề xuất họ mô hình Candidate-Constrained Transliteration (CCT) gồm hai phương pháp:

- **CCT-C (Classifier):** sử dụng bộ mã hóa BERT kết hợp với bộ phân loại MLP để lựa chọn trực tiếp một ứng viên tại từng vị trí. Toàn bộ chuỗi được suy luận song song nên có tốc độ xử lý nhanh.

- **CCT-D (Decoder):** bổ sung bộ giải mã Transformer nhằm mô hình hóa sự phụ thuộc giữa các token đầu ra trong quá trình sinh tự hồi quy, đồng thời vẫn duy trì ràng buộc tập ứng viên tại từng vị trí.

Hai phương pháp chia sẻ cùng bộ mã hóa BERT và token chỉ thị chiều chuyển tự, cho phép một mô hình duy nhất xử lý cả hai chiều chuyển tự Hán/Nôm ↔ Quốc ngữ.

Chi tiết các bước thực hiện gồm:

- **Bước 1. Khảo sát tài liệu:** nghiên cứu các công trình liên quan về chuyển tự Hán/Nôm, BERT, Transformer và các phương pháp dịch máy hiện đại.
- **Bước 2. Tiền xử lý dữ liệu:** chuẩn hóa ngữ liệu song song, xây dựng từ vựng thống nhất, tạo tập ứng viên từ ngữ liệu kết hợp với tự điển, đồng thời chia dữ liệu thành các tập huấn luyện, phát triển và kiểm tra.
- **Bước 3. Xây dựng mô hình cơ sở:** xây dựng mô hình Transformer làm đường cơ sở để so sánh với các phương pháp đề xuất.
- **Bước 4. Phát triển phương pháp CCT-C:** xây dựng mô hình phân loại token có ràng buộc tập ứng viên dựa trên bộ mã hóa BERT, tiến hành huấn luyện và đánh giá.
- **Bước 5. Phát triển phương pháp CCT-D:** bổ sung bộ giải mã Transformer trên nền bộ mã hóa dùng chung, tích hợp cơ chế ràng buộc tập ứng viên trong quá trình giải mã và thực hiện các thực nghiệm đánh giá.
- **Bước 6. Thực nghiệm và đánh giá:** so sánh các phương pháp trên các bộ dữ liệu Hán và Nôm ở cả hai chiều chuyển tự bằng độ đo BLEU, đồng thời phân tích ảnh hưởng của các cấu hình cụm từ cố định và thống kê tập ứng viên đến chất lượng chuyển tự.
- **Bước 7. Phân tích và tổng kết:** phân tích ưu điểm, hạn chế của các phương pháp đề xuất và đề xuất các hướng phát triển trong tương lai.

2.5 Kết quả dự kiến của đề tài

Đề tài dự kiến xây dựng được một hệ thống chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ dựa trên mô hình học sâu. Hai phương pháp đề xuất CCT-C và CCT-D được kỳ vọng cải thiện chất lượng chuyển tự so với mô hình Transformer cơ sở, đồng thời chứng minh hiệu quả của việc kết hợp bộ mã hóa hai chiều với cơ chế ràng buộc tập ứng viên. Ngoài việc đánh giá bằng độ đo BLEU trên cả bốn cấu hình dữ liệu (Hán/Nôm và hai chiều chuyển tự), đề tài cũng phân tích ảnh hưởng của chiến lược xây dựng tập ứng viên và cụm từ cố định đến chất lượng mô hình.

2.6 Kế hoạch thực hiện

Thời gian	Nội dung công việc
01/2026 – 02/2026	Khảo sát tài liệu, nghiên cứu các công trình liên quan về chuyển tự Hán/Nôm, BERT và Transformer.
02/2026 – 03/2026	Tiền xử lý ngữ liệu, xây dựng tập dữ liệu song song, từ vựng thống nhất và tập ứng viên từ ngữ liệu kết hợp tự điển.
03/2026 – 04/2026	Xây dựng mô hình Transformer cơ sở và thực hiện các thực nghiệm ban đầu.
04/2026 – 05/2026	Phát triển phương pháp CCT-C, huấn luyện và đánh giá trên các bộ dữ liệu Hán và Nôm.
05/2026 – 06/2026	Phát triển phương pháp CCT-D, thực hiện các thực nghiệm so sánh, phân tích kết quả và đánh giá ảnh hưởng của các cấu hình cụm từ cố định.
06/2026 – 07/2026	Hoàn thiện luận văn, tổng hợp kết quả, chỉnh sửa và chuẩn bị bảo vệ.

Bảng 2: Kế hoạch thực hiện đề tài

Tài liệu

- [1] N. Q. Hồng, *Khái luận văn tự học chữ Nôm*. Hà Nội: Nhà xuất bản Giáo dục, 2008.
- [2] D. Dinh, P. Nguyen, and L. H. B. Nguyen, “Transliterating Nôm scripts into Vietnamese national scripts using statistical machine translation,” *International Journal of Advanced Computer Science and Applications*, vol. 12, no. 2, 2021.
- [3] L. H. Thai, L. H. B. Nguyen, and D. Dinh, “Improve the automatic transliteration from Nôm scripts into Vietnamese national scripts by integrating Sino-Vietnamese knowledge into statistical machine translation,” in *Proceedings of the 4th International Conference on Information Technology and Computer Communications (ITCC)*, (New York, NY, USA), ACM, 2022.
- [4] L. H. B. Nguyen, T. M. Chien, T. H. Nguyen, and D. Dinh, “Nôm-scripts transliteration using multilingual neural machine translation approach,” in *Proceedings of the 14th National Conference on Fundamental and Applied Information Technology Research (FAIR 2021)*, 2021.
- [5] Viện Văn học, *Thơ văn Lý-Trần tập I*. Hà Nội: Nhà xuất bản Khoa học xã hội, 1977.
- [6] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of NAACL-HLT 2019*, (Minneapolis, MN, USA), pp. 4171–4186, Association for Computational Linguistics, 2019.
- [7] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “BLEU: a method for automatic evaluation of machine translation,” in *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, (Philadelphia, PA, USA), pp. 311–318, Association for Computational Linguistics, 2002.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày... tháng... năm...
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương	iv
Mục lục	xii
Danh sách hình	xvi
Danh sách bảng	xvii
Danh mục các từ viết tắt	xviii
Tóm tắt	xx
1 Giới thiệu	1
1.1 Bài toán chuyển tự trong dịch máy	1
1.2 Động lực và mục tiêu nghiên cứu	2
1.3 Hướng tiếp cận	2
1.3.1 Dữ liệu	3
1.3.2 Mô hình	3
1.4 Đóng góp	4
2 Cơ sở lý thuyết	5
2.1 Cơ sở ngôn ngữ học	5

2.1.1	Chữ Hán và cách đọc Hán Việt	6
2.1.2	Chữ Nôm và cấu tạo	6
2.1.3	Tính đa trị của chữ Hán Nôm	7
2.1.4	Căn chỉnh một đối một	8
2.1.5	Vai trò của tri thức Hán Việt	8
2.2	Transformer	9
2.2.1	Biểu diễn đầu vào và mã hóa vị trí	11
2.2.2	Kiến trúc bộ mã hóa	11
2.2.3	Chú ý đa đầu	12
2.2.4	Kiến trúc bộ giải mã	13
2.3	BERT	15
2.3.1	Kiến trúc	16
2.3.2	Vai trò của BERT trong khóa luận	17
2.4	Các công trình liên quan	17
2.4.1	Dịch máy nơ ron (NMT)	17
2.4.2	Dịch máy thống kê (SMT)	18
2.4.3	Ràng buộc không gian đầu ra	18
2.4.4	Định vị nghiên cứu	19
3	Phương pháp	21
3.1	Tổng quan phương pháp	21
3.2	Hình thức hóa bài toán	25
3.2.1	Giới hạn không gian đầu ra bằng tập ứng viên . . .	25
3.2.2	Xây dựng tập ứng viên	25
3.2.3	Mô hình xác suất	28
3.3	Token hóa dữ liệu	29
3.3.1	Token hóa ở cấp ký tự	29
3.3.2	Cụm từ cố định	29
3.3.3	Tập từ vựng thống nhất	30
3.4	Thành phần chung và điểm phân nhánh	31
3.4.1	Các thành phần chính	31

3.4.2	Bộ mã hóa BERT	32
3.4.3	Bảng nhúng đầu ra	33
3.4.4	Ràng buộc theo tập ứng viên	33
3.5	CCT-C: Phân loại cục bộ	34
3.5.1	Bộ chấm điểm	34
3.5.2	Giải mã song song	35
3.6	CCT-D: Giải mã tự hồi quy	35
3.6.1	Kiến trúc bộ giải mã	35
3.6.2	Đầu vào và ép giáo viên	36
3.6.3	Chấm điểm bằng tích vô hướng	37
3.6.4	Tìm kiếm chùm tia	39
3.7	Huấn luyện	40
3.7.1	Hàm mất mát	40
3.7.2	Quy trình huấn luyện	41
3.8	Suy luận	42
3.8.1	Gộp cụm từ	42
3.8.2	Suy luận với CCT-C	43
3.8.3	CCT-D: Tìm kiếm chùm tia	43
3.8.4	Xử lý token ngoài từ vựng	43
3.8.5	Tổng hợp đầu ra	44
3.9	Tóm tắt chương	44
4	Thực nghiệm	46
4.1	Dữ liệu	46
4.1.1	Tiền xử lý	47
4.1.2	Quy mô dữ liệu	48
4.1.3	Tổ chức dữ liệu theo hệ chữ	48
4.2	Độ đo đánh giá	49
4.2.1	Điểm BLEU	49
4.2.2	Độ chính xác theo vị trí	50
4.3	Thiết lập thực nghiệm	51

4.3.1	Mô hình so sánh	51
4.3.2	Cấu hình mô hình	53
4.3.3	Cấu hình huấn luyện	54
4.4	Kết quả	55
4.4.1	So sánh tổng thể	55
4.4.2	Ảnh hưởng của huấn luyện chung hai chiều	57
4.4.3	Ảnh hưởng của cụm từ cố định	59
4.5	Phân tích lỗi	60
4.5.1	Các dạng nhầm lẫn được quan sát	60
4.5.2	Phân tích một số nhóm lỗi chính	61
4.6	Giới hạn và hướng phát triển	62
4.6.1	Giới hạn	62
4.6.2	Hướng phát triển	62
5	Kết luận	64
	Danh mục công trình của tác giả	66
	Tài liệu tham khảo	67

Danh sách hình

2.1	Kiến trúc tổng quan của mô hình Transformer [20].	10
2.2	Cơ chế chú ý đa đầu [20].	13
3.1	Kiến trúc CCT-C (Classifier).	23
3.2	Kiến trúc CCT-D (Decoder).	24
3.3	Phân bố kích thước tập ứng viên trên dữ liệu Hán.	27
3.4	Phân bố kích thước tập ứng viên trên dữ liệu Nôm.	27

Danh sách bảng

3.1	Một số tập ứng viên $\mathcal{C}(x_i)$ theo hai chiều chuyển tự.	26
3.2	Thống kê kích thước tập ứng viên.	28
3.3	Cấu trúc tập từ vựng thống nhất.	31
4.1	Thống kê các tập dữ liệu (số lượng cặp câu).	48
4.2	Cấu hình hai mô hình CCT.	54
4.3	Thiết lập huấn luyện của hai phương pháp CCT và mô hình Transformer cơ sở.	55
4.4	Kết quả so sánh các mô hình trên tập kiểm tra (điểm BLEU).	56
4.5	Độ chính xác theo vị trí của hai mô hình CCT trên tập kiểm tra (%).	56
4.6	So sánh phương án huấn luyện chung hai chiều và huấn luyện riêng từng chiều (điểm BLEU).	58
4.7	Kết quả đầy đủ các mô hình theo cấu hình cụm từ cố định (điểm BLEU).	59
4.8	Ví dụ các dạng nhầm lẫn được quan sát.	60

Danh mục các từ viết tắt

Từ viết tắt	Nội dung tiếng Anh	Nội dung tiếng Việt
SMT	Statistical Machine Translation	Dịch máy thống kê
NMT	Neural Machine Translation	Dịch máy mạng nơ ron
RNN	Recurrent Neural Network	Mạng nơ ron hồi quy
LSTM	Long Short-Term Memory	Mạng bộ nhớ dài ngắn hạn
BERT	Bidirectional Encoder Representations from Transformers	Biểu diễn mã hóa hai chiều từ Transformer
GPT	Generative Pre-trained Transformer	Mô hình Transformer sinh đã được huấn luyện trước
T5	Text-to-Text Transfer Transformer	Mô hình Transformer chuyển đổi văn bản sang văn bản
MLM	Masked Language Modeling	Mô hình hóa ngôn ngữ có mặt nạ
NSP	Next Sentence Prediction	Dự đoán câu tiếp theo
CLS	Classification token	Token phân loại
SEP	Separator token	Token phân tách
FFN	Feed-Forward Network	Mạng truyền xuôi
LN	Layer Normalization	Chuẩn hóa lớp
GELU	Gaussian Error Linear Unit	Hàm kích hoạt GELU

Từ viết tắt	Nội dung tiếng Anh	Nội dung tiếng Việt
MLP	Multi-Layer Perceptron	Mạng perceptron đa lớp
BLEU	Bilingual Evaluation Understudy	Điểm đánh giá BLEU
CCT	Candidate-Constrained Transliteration	Chuyển tự ràng buộc ứng viên
CCT-C	CCT with Classifier	CCT dùng bộ phân loại
CCT-D	CCT with Decoder	CCT dùng bộ giải mã
OOV	Out-of-Vocabulary	Ngoài từ vựng
UNK	Unknown token	Token không xác định
PAD	Padding token	Token đệm
BOS	Beginning of Sequence	Token bắt đầu chuỗi
EOS	End of Sequence	Token kết thúc chuỗi
FP16	16-bit Floating Point	Số thực dấu phẩy động 16 bit độ chính xác bán phần
BF16	Brain Floating Point 16-bit	Số thực dấu phẩy động 16 bit dạng bfloat16
XML	Extensible Markup Language	Ngôn ngữ đánh dấu mở rộng

Tóm tắt

Khóa luận nghiên cứu bài toán chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ bằng các mô hình dịch máy, nhằm hỗ trợ số hóa và khai thác tư liệu Hán Nôm. Bài toán có quan hệ ánh xạ đa trị: một ký tự Hán/Nôm có thể có nhiều cách đọc Quốc ngữ, trong khi một âm Quốc ngữ cũng có thể tương ứng với nhiều ký tự Hán/Nôm. Việc lựa chọn đầu ra vì vậy phụ thuộc vào ngữ cảnh và trở nên khó khăn hơn khi ngữ liệu song song còn hạn chế.

Khóa luận xây dựng và đánh giá họ mô hình CCT bằng cách khai thác đặc trưng căn chỉnh gần một đối một và áp dụng ràng buộc tập ứng viên tại mỗi vị trí; tập ứng viên được xây dựng từ dữ liệu song song cùng tự điển. Trên nền bộ mã hóa BERT, CCT-C lựa chọn token đích độc lập tại từng vị trí, còn CCT-D bổ sung bộ giải mã Transformer để mô hình hóa sự phụ thuộc giữa các token đích. Token chỉ thị chiều chuyển tự cho phép một mô hình xử lý hai chiều trong cùng một hệ chữ.

Trên tập kiểm tra Hán và Nôm (Bảng 4.4), CCT-D đạt điểm BLEU cao hơn mô hình Transformer cơ sở ở cả bốn cấu hình, còn CCT-C đạt cao hơn ở ba cấu hình. Mức chênh lệch lớn nhất là 14.55 điểm BLEU ở chiều Quốc ngữ $\rightarrow$ Nôm với CCT-D. Độ chính xác theo vị trí cũng cho thấy CCT-D cao hơn CCT-C ở ba trong bốn cấu hình. Phương án huấn luyện chung hai chiều đạt điểm BLEU cao hơn phương án huấn luyện riêng từng chiều ở cả tám cấu hình so sánh (Bảng 4.6). Các kết quả này ghi nhận chất lượng của hai hệ thống hoàn chỉnh trong thiết lập được khảo sát; do chưa có thí nghiệm loại bỏ ràng buộc tập ứng viên, chúng chưa tách riêng

đóng góp của thành phần này khỏi các khác biệt kiến trúc. Ảnh hưởng riêng của độ nhập nhằng và quy mô dữ liệu cũng cần được kiểm chứng bằng thực nghiệm có kiểm soát.

Chương 1

Giới thiệu

1.1 Bài toán chuyển tự trong dịch máy

Khóa luận nghiên cứu bài toán dịch máy giữa chữ Hán/Nôm và chữ Quốc ngữ. Chuyển tự, hay dịch âm, là quá trình thay thế các đơn vị của một hệ chữ viết bằng các đơn vị tương ứng trong hệ chữ viết khác, nhằm biểu diễn cách đọc thay vì chuyển nghĩa [9], [1].

Ở chiều Hán/Nôm $\rightarrow$ Quốc ngữ, chữ Nôm vốn dùng để ghi tiếng Việt nên quá trình chuyển đổi là chuyển tự [1], [10]. Với chữ Hán, cần phân biệt giữa chuyển tự sang âm Hán Việt và dịch nghĩa sang tiếng Việt hiện đại. Dữ liệu của khóa luận chỉ gồm các cặp chữ Hán/Nôm và cách đọc tương ứng bằng Quốc ngữ; vì vậy, khóa luận chỉ khảo sát bài toán chuyển tự theo hai chiều, không xử lý bài toán dịch nghĩa cho chữ Hán.

Trong khóa luận, chuyển tự là một bài toán dịch máy, trong đó mô hình học ánh xạ giữa chuỗi nguồn và chuỗi đích từ ngữ liệu song song [1], [11]. Thuật ngữ “chuyển tự” sẽ được sử dụng xuyên suốt các phần tiếp theo.

1.2 Động lực và mục tiêu nghiên cứu

Một hệ thống chuyển tự chữ Hán/Nôm sang chữ Quốc ngữ có thể hỗ trợ số hóa và tra cứu văn bản cổ, qua đó phục vụ nghiên cứu văn học, lịch sử và ngôn ngữ học. Vai trò này đã được đặt ra trong các nghiên cứu chuyển tự chữ Nôm sang Quốc ngữ [10]. Chiều chuyển tự ngược lại cũng hữu ích khi đối chiếu cách ghi một âm Quốc ngữ bằng các ký tự Hán/Nôm tương ứng.

Các phương pháp dựa trên tự điển hoặc luật ký tự gặp khó khăn trước hiện tượng đa trị: quan hệ giữa ký tự nguồn và cách đọc không luôn là một-một; chẳng hạn, một chữ Nôm có thể tương ứng với nhiều cách đọc Quốc ngữ khác nhau [1]. Vì vậy, lựa chọn không chỉ phụ thuộc vào ký tự đang xét mà còn vào ngữ cảnh bên trái và bên phải của nó trong câu.

Từ những nhận định trên, khóa luận đặt mục tiêu xây dựng một hệ thống chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ có khả năng xử lý hiện tượng đa trị trong điều kiện ngữ liệu song song hạn chế. Mục tiêu này gồm ba yêu cầu: (i) dựa vào ngữ cảnh hai chiều của câu để chọn đúng cách đọc cho từng ký tự; (ii) tận dụng tri thức từ tự điển và ngữ liệu để thu hẹp không gian dự đoán; (iii) xử lý cả hai chiều trong cùng một mô hình để dùng trọn nguồn dữ liệu hiện có.

1.3 Hướng tiếp cận

Các nghiên cứu trước đây về chuyển tự chữ Nôm sang Quốc ngữ chủ yếu áp dụng mô hình dịch máy thống kê hoặc nơ ron theo khuôn khổ sinh chuỗi [10], [2], [12], [13], [14]; một số công trình đồng thời mở rộng và tổ chức ngữ liệu theo lĩnh vực [15]. Ở chiều ngược lại, mô hình dựa trên Transformer đã được áp dụng cho chuyển tự từ Quốc ngữ sang Hán/Nôm [16]. Trong cùng khuôn khổ dịch máy, khóa luận khai thác thêm đặc trưng căn chỉnh gần một đối một giữa chuỗi nguồn và chuỗi đích để giới hạn lựa chọn đầu ra tại từng vị trí. Hướng tiếp cận được trình bày theo hai khía cạnh:

cách tổ chức dữ liệu và cách xây dựng mô hình.

1.3.1 Dữ liệu

Khóa luận sử dụng các nguồn dữ liệu do Trung tâm Ngôn ngữ học Tính toán, Trường Đại học Khoa học Tự nhiên cung cấp; nguồn và quy mô dữ liệu được mô tả cụ thể trong Chương 4. Khác với cách tổ chức theo lĩnh vực hoặc dùng tri thức Hán Việt như thành phần hỗ trợ cho dịch máy thống kê [15], dữ liệu trong khóa luận được chia thành hai hệ chuyển tự độc lập: Hán $\leftrightarrow$ Quốc ngữ và Nôm $\leftrightarrow$ Quốc ngữ. Mỗi hệ chữ có một mô hình riêng để tránh trộn lẫn các quy luật ánh xạ và không gian ký tự khác nhau. Bên cạnh ngữ liệu song song, tự điển Hán/Nôm được dùng để xây dựng tập ứng viên cho từng token nguồn. Tập này gồm các token đích mà hệ thống cho phép lựa chọn tại vị trí tương ứng.

1.3.2 Mô hình

Khóa luận chọn bộ mã hóa hai chiều BERT [17] để biểu diễn ngữ cảnh ở cả hai phía của từng ký tự. Do chuỗi nguồn và chuỗi đích căn chỉnh gần một đối một, tại mỗi vị trí, mô hình chỉ dự đoán trên tập ứng viên đã xây dựng cho ký tự nguồn thay vì toàn bộ từ vựng đích. Không gian đầu ra vì thế được giới hạn, đồng thời ràng buộc ngôn ngữ học của bài toán được tích hợp vào mô hình.

Từ ý tưởng này, khóa luận xây dựng họ mô hình Candidate-Constrained Transliteration (CCT) gồm hai phương pháp CCT-C (Classifier) và CCT-D (Decoder). CCT-C phân loại độc lập tại từng vị trí, còn CCT-D bổ sung bộ giải mã Transformer có ràng buộc tập ứng viên để mô hình hóa sự phụ thuộc giữa các ký tự đầu ra. Trong mỗi mô hình, mỗi cặp dữ liệu được sử dụng để tạo hai mẫu huấn luyện tương ứng với hai chiều chuyển tự, được phân biệt bằng token chỉ thị chiều.

1.4 Đóng góp

Các đóng góp chính của khóa luận bao gồm:

- Xây dựng họ mô hình Candidate-Constrained Transliteration (CCT) cho chuyển tự hai chiều giữa chữ Hán/Nôm và chữ Quốc ngữ bằng cách áp dụng ràng buộc tập ứng viên tại từng vị trí. Họ mô hình gồm CCT-C lựa chọn độc lập tại từng vị trí và CCT-D sử dụng bộ giải mã Transformer để khai thác thông tin từ các token đầu ra trước đó.
- Huấn luyện chung hai chiều chuyển tự trong một mô hình cho mỗi hệ chữ. Token chỉ thị chiều được dùng để mô hình phân biệt hai tác vụ. So với huấn luyện riêng từng chiều, phương án này đạt điểm BLEU cao hơn ở cả tám cấu hình so sánh (Bảng 4.6).
- Đánh giá thực nghiệm trên cả dữ liệu Hán và Nôm. Trong thiết lập của khóa luận, CCT-D đạt điểm BLEU cao hơn mô hình Transformer cơ sở ở cả bốn cấu hình và đạt kết quả cao nhất ở ba cấu hình, với mức chênh lệch lớn nhất là 14.55 điểm BLEU (Bảng 4.4). Độ chính xác theo vị trí cũng cho thấy CCT-D cao hơn CCT-C ở ba trong bốn cấu hình (Bảng 4.5).

Chương 2

Cơ sở lý thuyết

Chương này kết nối đặc trưng ngôn ngữ học của chữ Hán/Nôm với lựa chọn mô hình trong khóa luận. Phần đầu phân tích hiện tượng đa trị và quan hệ căn chỉnh gần một đối một; phần tiếp theo trình bày Transformer và BERT; phần cuối tổng hợp các công trình liên quan để xác định khoảng trống mà họ mô hình CCT hướng tới. Theo phạm vi đã xác định ở Chương 1, các phương pháp dịch máy được trình bày trong chương này được sử dụng để thực hiện chuyển tự.

2.1 Cơ sở ngôn ngữ học

Đặc trưng của bài toán chuyển tự được khảo sát bắt nguồn từ quan hệ giữa tự dạng Hán Nôm, âm đọc và nghĩa. Quan hệ giữa tự dạng và âm đọc không phải lúc nào cũng là ánh xạ duy nhất: một đơn vị nguồn có thể tương ứng với nhiều đơn vị đích. Tuy nhiên, các phương án đã ghi nhận trong ngữ liệu và tự điển vẫn có thể được tập hợp thành một tập ứng viên hữu hạn. Đây là cơ sở ngôn ngữ học của phương pháp được trình bày ở Chương 3.

Trong phần này, “gọi âm” và “gọi nghĩa” được dùng để mô tả chức năng của thành phần hoặc cách mượn một chữ cụ thể, không phải để phân chia tuyệt đối toàn bộ hệ chữ thành “ghi âm” hoặc “ghi ý”. Một chữ có thể đồng thời chứa thông tin về âm đọc và nghĩa.

2.1.1 Chữ Hán và cách đọc Hán Việt

Chữ Hán thường được mô tả là hệ chữ ngữ tố âm tiết: mỗi chữ thường gắn với một âm tiết và một ngữ tố, còn các thành phần cấu tạo có thể gọi âm hoặc gọi nghĩa [18]. Chữ Quốc ngữ là hệ chữ cái ghi âm, dùng chữ cái và dấu thanh để biểu diễn âm thanh tiếng Việt. Do đó, chuyển từ chữ Hán sang Quốc ngữ đòi hỏi xác định cách đọc của chữ trong ngữ cảnh.

Trong quá trình tiếp xúc với tiếng Hán, tiếng Việt hình thành hệ thống cách đọc Hán Việt. Các âm gốc Hán trong tiếng Việt thường được chia thành ba lớp theo thời điểm du nhập [3], [4]:

- Âm tiền Hán Việt (Hán Việt cổ): vào tiếng Việt từ trước đời Đường, nay đã hòa vào lớp từ vựng thông dụng và dấu vết nguồn gốc Hán không còn dễ nhận biết, như “務”: “mùa”, “味”: “mùi”, “鮮”: “tươi”.
- Âm Hán Việt: hình thành trên nền ngữ âm đời Đường, ổn định lại từ thời tự chủ; đây là lớp âm quy chuẩn khi đọc chữ Hán trong sách vở, tương ứng “務”: “vụ”, “味”: “vị”, “鮮”: “tiên”.
- Âm hậu Hán Việt: là âm Hán Việt đã tiếp tục biến đổi trong quá trình sử dụng trong tiếng Việt, như “蓮”: “sen” (bên cạnh “liên”), “本”: “vốn” (bên cạnh “bổn”), “肝”: “gan” (bên cạnh “can”).

Một chữ Hán cũng có thể mang nhiều âm Hán Việt tùy theo nghĩa, tức hiện tượng đa âm tự. Chẳng hạn, “行” có thể đọc là “hành”, “hàng” hoặc “hạnh”; “樂” có thể đọc là “nhạc”, “lạc” hoặc “nhạo”. Vì vậy, cách đọc phù hợp phải được lựa chọn theo ngữ cảnh.

2.1.2 Chữ Nôm và cấu tạo

Để ghi tiếng Việt, đặc biệt là các từ không có sẵn chữ Hán tương ứng, người Việt mượn chữ Hán hoặc tạo chữ mới trên cơ sở các thành phần của chữ Hán [5], [6], [7]. Ba cách tiêu biểu dưới đây cho thấy vì sao tự dạng, âm đọc và nghĩa có thể liên hệ với nhau theo nhiều kiểu [5], [7].

Giả tá. Cách này dùng nguyên một chữ Hán có sẵn để ghi một đơn vị tiếng Việt. Việc mượn có thể dựa vào âm, nghĩa hoặc cả hai [5]. Chẳng hạn, “德” giữ nghĩa và được đọc theo âm Hán Việt “đức”; “半” được mượn theo âm “bán” để ghi tiếng “bán” trong “buôn bán”, không giữ nghĩa gốc; “別” có âm Hán Việt “biệt” và được mượn để ghi “biết” do gần âm; còn “為” được mượn theo nghĩa và đọc là “làm”. Như vậy, cùng một tự dạng không nhất thiết giữ đồng thời âm đọc và nghĩa gốc của chữ Hán.

Hình thanh. Một thành phần gợi nghĩa được ghép với một thành phần gợi âm để tạo chữ mới. Cách mô tả này cho thấy tự dạng có thể đồng thời cung cấp thông tin về nghĩa và âm đọc, nhưng mức độ gợi âm hoặc gợi nghĩa không nhất thiết hoàn toàn chính xác trong mọi trường hợp [6], [7].

Hội ý. Các thành phần được kết hợp theo nghĩa để biểu thị nghĩa chung của chữ mới [5], [7].

Do được sử dụng qua nhiều thời kỳ mà không có một chuẩn tự dạng thống nhất, chữ Nôm tồn tại nhiều dị thể; một tiếng Việt có thể được ghi bằng các chữ khác nhau tùy theo văn bản, thời kỳ hoặc vùng sử dụng [5], [6]. Đối với mô hình, hiện tượng này làm tăng số tự dạng cần xử lý và khiến nhiều chữ chỉ xuất hiện với tần suất thấp. Các thống kê trên dữ liệu của khóa luận được trình bày ở Chương 4.

2.1.3 Tính đa trị của chữ Hán Nôm

Tính đa trị bắt nguồn từ nhiều đặc điểm của hệ chữ. Một chữ có thể có nhiều cách đọc Quốc ngữ do hiện tượng đa âm của chữ Hán hoặc do được mượn theo nhiều cách. Chẳng hạn, “味” có thể được đọc là “mùi”, “vị” hoặc “màu” [6]. Cách đọc còn thay đổi theo vùng miền và thời đại, chẳng hạn “眉” đọc “mi” ở Trung Bộ nhưng “mây” ở Bắc Bộ, “榮” đọc “vang” ở Nam Bộ nhưng “vinh” ở Bắc Bộ [8]. Ngoài ra, một từ có thể được ghi bằng nhiều chữ.

Mức độ đa trị cũng khác nhau giữa hai chiều chuyển tự. Một âm tiết Quốc ngữ có thể tương ứng với nhiều chữ do hiện tượng đồng âm và sự tồn tại của các dị thể. Trong tập ứng viên được xây dựng cho khóa luận, vì vậy, chiều Quốc ngữ $\rightarrow$ Hán/Nôm có số ứng viên trung bình lớn hơn chiều Hán/Nôm $\rightarrow$ Quốc ngữ. Số liệu cụ thể được trình bày ở Mục 3.2.2 và Bảng 3.2.

Tính đa trị là một thuộc tính của hệ chữ, không đơn thuần là nhiều dữ liệu. Tập hợp các ánh xạ ghi nhận trong ngữ liệu và tự diễn thành một tập hữu hạn cho phép đưa tri thức này vào mô hình dưới dạng ràng buộc đầu ra. Tập ứng viên giảm không gian dự đoán, nhưng không loại bỏ yêu cầu phân biệt các phương án theo ngữ cảnh.

2.1.4 Căn chỉnh một đối một

Tiếng Việt thường được mô tả là ngôn ngữ đơn lập, trong đó hình vị thường có một âm tiết và các âm tiết được viết tách nhau [19]; mỗi chữ Hán hoặc chữ Nôm cũng thường ghi một âm tiết [7]. Đặc điểm này tạo cơ sở cho việc căn chỉnh các đơn vị theo vị trí, nhưng không bảo đảm mọi cặp văn bản đều có quan hệ một đối một.

Trong khóa luận, giả thiết mỗi token nguồn ứng với một token đích được áp dụng sau bước tiền xử lý: chỉ các cặp có cùng số token ở hai phía được giữ lại, và thứ tự tương ứng được bảo toàn. Những trường hợp một chữ ghi nhiều âm tiết hoặc hai phía không thể tách thành số đơn vị bằng nhau nằm ngoài phạm vi dữ liệu hiện tại. Cơ chế cụm từ cố định ở Mục 3.8 chỉ xử lý các chuỗi nhiều token có số đơn vị bằng nhau, không khắc phục các trường hợp lệch độ dài. Đây là một giới hạn được thảo luận tại Mục 4.6.

2.1.5 Vai trò của tri thức Hán Việt

Lớp từ gốc Hán chiếm một bộ phận đáng kể trong vốn từ tiếng Việt và có hệ thống cách đọc Hán Việt tương đối ổn định [4]. Vì vậy, các tự diễn


Hán Việt và Nôm/Quốc ngữ được dùng làm nguồn trực tiếp để xây dựng và mở rộng tập ứng viên ở Mục 3.2.2. Bảng cụm từ cố định là một nguồn dữ liệu riêng nhưng được sử dụng cùng với tự điển trong các cấu hình có xử lý cụm từ: tự điển mở rộng các ánh xạ ứng viên, còn bảng cụm từ cung cấp các ánh xạ cho chuỗi nhiều token. Cơ chế sử dụng cụm từ được trình bày tại Mục 3.8.

Những đặc trưng ngôn ngữ học trên đặt ra yêu cầu về mặt mô hình: cần một kiến trúc nắm được ngữ cảnh hai chiều để phân biệt các cách đọc. Kiến trúc Transformer và BERT trong các mục tiếp theo chính là nền tảng đáp ứng yêu cầu đó.

2.2 Transformer

Kiến trúc Transformer [20] là nền tảng lý thuyết cho các mô hình CCT trong khóa luận này. Khác với các kiến trúc tuần tự như RNN hay LSTM, Transformer xử lý các vị trí của chuỗi đầu vào song song thông qua cơ chế tự chú ý (self-attention), không cần truyền trạng thái lần lượt qua từng vị trí.

Transformer được đề xuất cho bài toán dịch máy với kiến trúc bộ mã hóa và bộ giải mã (encoder-decoder): bộ mã hóa chuyển câu nguồn thành chuỗi biểu diễn ngữ cảnh, bộ giải mã sinh câu đích tự hồi quy dựa trên các biểu diễn đó. Tổng quan kiến trúc được minh họa trong Hình 2.1.



Hình 2.1: Kiến trúc tổng quan của mô hình Transformer [20].

2.2.1 Biểu diễn đầu vào và mã hóa vị trí

Transformer không sử dụng cấu trúc tuần tự, do đó cơ chế tự chú ý không tự mang thông tin về thứ tự token. Để bổ sung thông tin vị trí, Transformer cộng thêm mã hóa vị trí (positional encoding) vào véc tơ nhúng (embedding) đầu vào trước khi đưa vào mạng.

Trong Transformer gốc, mã hóa vị trí được định nghĩa bằng các hàm sin và cos cố định:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad (2.1)$$

trong đó pos là vị trí token trong chuỗi, i là chỉ số chiều ($0 \leq i < d_{\text{model}}/2$) và d_{model} là số chiều véc tơ nhúng. Với một độ lệch k cố định, PE_{pos+k} có thể biểu diễn bằng một phép biến đổi tuyến tính của PE_{pos} .

Quan hệ theo độ lệch vị trí là một lý do Transformer gốc lựa chọn mã hóa hình sin. Tuy nhiên, khả năng tổng quát sang chuỗi dài hơn còn phụ thuộc vào dữ liệu và cách huấn luyện, nên riêng tính chất này không bảo đảm chất lượng ở những độ dài chưa quan sát.

2.2.2 Kiến trúc bộ mã hóa

Bộ mã hóa nhận chuỗi đầu vào $x = (x_1, \dots, x_S)$ và ánh xạ thành chuỗi biểu diễn ngữ cảnh liên tục $\mathbf{h} = (h_1, \dots, h_S)$, trong đó mỗi h_i mã hóa thông tin ngữ cảnh hai chiều của token x_i .

Mỗi lớp bộ mã hóa gồm hai mô-đun: (1) tự chú ý đa đầu (multi-head self-attention) và (2) mạng truyền xuôi theo vị trí (position-wise feed-forward network, FFN). Cả hai được bao bởi kết nối dư (residual connection) và chuẩn hóa lớp (layer normalization) theo cấu trúc Post-LN (chuẩn hóa sau kết nối dư):

$$\text{Output} = \text{LayerNorm}(x + \text{Sublayer}(x)), \quad (2.2)$$

trong đó x là đầu vào mô-đun, $\text{Sublayer}(\cdot)$ là phép biến đổi của mô-đun đó (tầng tự chú ý hoặc FFN).

Sau tầng tự chú ý, mỗi vị trí được đưa qua FFN áp dụng độc lập:

$$\text{FFN}(x) = \text{Activation}(xW_1 + b_1)W_2 + b_2, \quad (2.3)$$

trong đó $W_1 \in \mathbb{R}^{d_{\text{model}} \times d_{\text{ff}}}$, $b_1 \in \mathbb{R}^{d_{\text{ff}}}$ là tham số lớp chiếu lên không gian ẩn; $W_2 \in \mathbb{R}^{d_{\text{ff}} \times d_{\text{model}}}$, $b_2 \in \mathbb{R}^{d_{\text{model}}}$ là tham số lớp chiếu trở về; d_{ff} là số chiều không gian ẩn (thường $d_{\text{ff}} = 4d_{\text{model}}$). Transformer gốc dùng ReLU, còn BERT và khóa luận này dùng GELU [17], [20].

Bộ mã hóa là một ngăn xếp gồm nhiều lớp có cùng cấu trúc nhưng tham số riêng. Qua từng lớp, biểu diễn của mỗi token tiếp tục được cập nhật bằng thông tin từ các vị trí còn lại trong chuỗi.

2.2.3 Chú ý đa đầu

Với cơ chế chú ý, mỗi vị trí có thể tập trung vào các phần khác nhau của chuỗi khi xây dựng biểu diễn. Transformer dùng chú ý tích vô hướng có tỉ lệ (Scaled Dot-Product Attention):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V, \quad (2.4)$$


trong đó $Q \in \mathbb{R}^{n \times d_k}$ là ma trận truy vấn (query), $K \in \mathbb{R}^{m \times d_k}$ là ma trận khóa (key), $V \in \mathbb{R}^{m \times d_v}$ là ma trận giá trị (value); n, m lần lượt là độ dài chuỗi truy vấn và chuỗi nguồn, d_k, d_v là số chiều khóa và giá trị. Hệ số $1/\sqrt{d_k}$ kiểm soát độ lớn của tích vô hướng, hạn chế softmax rơi vào vùng bão hòa khi d_k lớn.

Chú ý đa đầu thực hiện h phép chú ý song song trên các không gian con khác nhau, mỗi đầu áp dụng hàm chú ý ở công thức (2.4):

$$\begin{aligned} \text{MultiHead}(Q, K, V) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \\ \text{head}_i &= \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \end{aligned} \quad (2.5)$$

trong đó $W_i^Q, W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ và $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ là các ma trận chiếu riêng của đầu chú ý thứ i ; $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ là ma trận chiếu đầu ra; $d_k = d_v = d_{\text{model}}/h$. Các phép chiếu riêng cho phép các đầu chú ý học những mẫu quan hệ khác nhau trong cùng một lớp.

Trong bộ mã hóa, tự chú ý dùng $Q = K = V = H$ (chuỗi đầu vào của lớp đó), nên mỗi vị trí tương tác trực tiếp với tất cả vị trí còn lại trong cùng một bước tính toán.



Hình 2.2: Cơ chế chú ý đa đầu [20].

2.2.4 Kiến trúc bộ giải mã

Bộ giải mã sinh chuỗi đích tự hồi quy: tại mỗi bước t , bộ giải mã nhận biểu diễn của các token đích đã sinh $(y_1, \dots, y_{t-1})$ và biểu diễn bộ mã hóa H , rồi dự đoán token y_t .

Mỗi lớp bộ giải mã gồm ba mô-đun theo thứ tự:

Tự chú ý có mặt nạ (Masked Self-Attention). Để ngăn vị trí truy vấn i chú ý đến các vị trí tương lai $j > i$, bộ giải mã sử dụng ma trận mặt nạ nhân quả cộng tính $M \in \mathbb{R}^{n \times n}$, với n là độ dài chuỗi đầu vào của bộ giải mã. Mỗi phần tử của ma trận được xác định bởi

$$M_{ij} = \begin{cases} 0 & \text{nếu } i \geq j, \\ -\infty & \text{nếu } i < j, \end{cases} \quad (2.6)$$

trong đó i là vị trí truy vấn và j là vị trí khóa. Ma trận M được cộng vào ma trận điểm $QK^\top / \sqrt{d_k}$ trước khi áp dụng softmax.

Đầu ra của cơ chế chú ý có mặt nạ là

$$\text{MaskedAttention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right) V. \quad (2.7)$$

Cơ chế này đảm bảo khi sinh y_t , bộ giải mã chỉ nhìn thấy $y_1, \dots, y_{t-1}$.

Chú ý chéo (Cross-Attention). Ma trận truy vấn Q lấy từ đầu ra tự chú ý có mặt nạ của bộ giải mã; ma trận khóa K và giá trị V lấy từ biểu diễn bộ mã hóa H :

$$\text{CrossAttention}(Q_{\text{dec}}, K_{\text{enc}}, V_{\text{enc}}) = \text{softmax}\left(\frac{Q_{\text{dec}} K_{\text{enc}}^\top}{\sqrt{d_k}}\right) V_{\text{enc}}. \quad (2.8)$$

Tại mỗi bước t , bộ giải mã vì thế tổng hợp được thông tin từ bất kỳ vị trí nào trong chuỗi nguồn.

Mạng truyền xuôi (Feed-Forward Network). Tương tự bộ mã hóa, áp dụng độc lập trên từng vị trí.

Ba mô-đun trên đều được bao bởi kết nối dư và chuẩn hóa lớp. Bên cạnh biến thể Post-LN gốc (chuẩn hóa sau kết nối dư), một biến thể phổ biến

là Pre-LN [21], trong đó chuẩn hóa lớp được áp dụng trước mỗi mô-đun:

$$\text{Output} = x + \text{Sublayer}(\text{LayerNorm}(x)). \quad (2.9)$$

Pre-LN đã được kiểm chứng là ổn định hơn về mặt tối ưu so với Post-LN gốc khi huấn luyện mạng sâu từ đầu.

Ép giáo viên (Teacher Forcing). Trong pha huấn luyện, thay vì dùng token vừa sinh $\hat{y}_{t-1}$ (có thể sai ở giai đoạn đầu), bộ giải mã nhận nhãn đúng y_{t-1}^* làm đầu vào tại bước t [22], [23]. Khi đó mô hình điều kiện hóa trên các token đích đúng ở những bước trước và không tích lũy lỗi dự đoán giữa các bước trong pha huấn luyện. Trong pha suy luận, bộ giải mã hoạt động tự hồi quy: đầu vào tại bước t là token do chính mô hình sinh ở bước $t - 1$.

2.3 BERT

BERT (Bidirectional Encoder Representations from Transformers) [17] là kiến trúc bộ mã hóa Transformer được thiết kế để mã hóa biểu diễn ngữ cảnh hai chiều: mỗi token thu thập thông tin từ toàn bộ chuỗi (cả bên trái lẫn bên phải) trong cùng một lớp tự chú ý.

Đây là điểm khác biệt cốt lõi so với các mô hình tự hồi quy như GPT [24], vốn xử lý chuỗi theo một chiều (trái sang phải). Với bài toán mã hóa (encoding) thay vì sinh (generation), biểu diễn hai chiều là lựa chọn tự nhiên: mỗi h_i tổng hợp được đầy đủ ngữ cảnh của x_i trong câu x .

2.3.1 Kiến trúc

Về cấu trúc, BERT là một ngăn xếp gồm nhiều lớp bộ mã hóa Transformer (Mục 2.2.2): mỗi lớp gồm tự chú ý đa đầu và FFN, được bao bởi kết nối dư và chuẩn hóa lớp. BERT không có bộ giải mã.

Điểm khác biệt so với bộ mã hóa Transformer gốc:

- Dùng véc tơ nhúng vị trí học được thay vì mã hóa vị trí hình sin cố định;
- Biểu diễn đầu vào là tổng của ba thành phần:

$$E = E_{\text{token}} + E_{\text{position}} + E_{\text{segment}} \quad (2.10)$$

trong đó

- E_{token} là véc tơ nhúng của ký hiệu token
 - E_{position} là véc tơ nhúng vị trí
 - E_{segment} là véc tơ nhúng phân đoạn câu (dùng để phân biệt hai câu trong cùng một đầu vào);
- Thêm token đặc biệt [CLS] ở đầu chuỗi (dùng cho phân loại câu) và [SEP] phân tách câu.

Biểu thức trên mô tả lớp nhúng của BERT gốc. Trong BERT, nhúng phân đoạn cho biết mỗi token thuộc câu thứ nhất hay câu thứ hai khi đầu vào gồm một cặp câu. Trong khóa luận, mỗi mẫu chỉ có một chuỗi nguồn nên mọi token thuộc cùng một phân đoạn và nhận cùng một véc tơ E_{segment} . Thành phần này vì thế không cung cấp thông tin để phân biệt hai chiều chuyển tự. Hai chiều được phân biệt bằng token chỉ thị [vi2no] hoặc [no2vi] ở đầu chuỗi, như trình bày tại Chương 3.

2.3.2 Vai trò của BERT trong khóa luận

Trong khóa luận này, BERT giữ vai trò bộ mã hóa hai chiều: mỗi biểu diễn đầu ra tổng hợp thông tin từ cả ngữ cảnh bên trái lẫn bên phải của ký tự, đúng với yêu cầu phân biệt các cách đọc của một ký tự đa trị đã nêu ở Mục 2.1.3.

Khóa luận chỉ kế thừa kiến trúc bộ mã hóa, không sử dụng các tác vụ tiền huấn luyện của BERT gốc như Masked Language Modeling (MLM) và Next Sentence Prediction (NSP). Do từ vựng và cách mã hóa đầu vào của các mô hình tiền huấn luyện sẵn có không trực tiếp phù hợp với thiết lập gồm cả chữ Hán/Nôm lẫn chữ Quốc ngữ, khóa luận không sử dụng trọng số tiền huấn luyện mà huấn luyện bộ mã hóa từ đầu trên ngữ liệu song song. Cách các biểu diễn ngữ cảnh này được dùng để lựa chọn đầu ra trong tập ứng viên sẽ được trình bày trong Chương 3.

2.4 Các công trình liên quan

Phần này khảo sát hai hướng liên quan trực tiếp đến khóa luận: chuyển tự Hán/Nôm và ràng buộc không gian đầu ra. Từ đó, phần cuối xác định khoảng trống nghiên cứu và vị trí của họ mô hình CCT.

Phạm vi khảo sát chỉ gồm các công trình chuyển đổi giữa tự dạng Hán/Nôm và cách đọc tương ứng bằng Quốc ngữ. Các công trình dịch nội dung văn bản Hán Nôm sang tiếng Việt hiện đại không thuộc phạm vi này.

2.4.1 Dịch máy nơ ron (NMT)

Các nghiên cứu NMT ban đầu chủ yếu tập trung vào chiều Nôm sang Quốc ngữ với hơn 6.000 cặp câu song song. Mô hình song ngữ đạt 75.80 BLEU [2]. Khi sử dụng Transformer đa ngữ để khai thác thêm dữ liệu tiếng Anh và tiếng Hoa, kết quả đạt 76.12 BLEU [1]. Các nghiên cứu sau đó tiếp tục khảo sát chia sẻ tham số và BERT-NMT cho chiều Nôm sang

Quốc ngữ [14].

Chiều từ Quốc ngữ sang Hán/Nôm được khảo sát muộn hơn. Dương và cộng sự [16] xây dựng hai mô hình T5 riêng cho chữ Hán và chữ Nôm. Dữ liệu của nhánh Nôm ít hơn nhiều so với nhánh Hán.

2.4.2 Dịch máy thống kê (SMT)

Nghiên cứu [10] áp dụng Moses SMT cho chiều Nôm sang Quốc ngữ. Mô hình học các cặp cụm dựa trên ngữ liệu song song; các ánh xạ trong tự điển Hán/Nôm và Quốc ngữ được bổ sung vào cùng bảng cụm từ. Ngữ liệu Quốc ngữ đơn ngữ được dùng để huấn luyện mô hình ngôn ngữ n-gram nhằm lựa chọn phương án phù hợp với ngữ cảnh. Kết quả cao nhất đạt được là 85.76 BLEU.

Các công trình tiếp theo điều chỉnh mô hình ngôn ngữ cho cùng chiều chuyển tự. Nghiên cứu [12] dùng mô hình 4-gram huấn luyện trên ngữ liệu Quốc ngữ theo thể loại và lĩnh vực. Nghiên cứu [13] sử dụng mô hình ngôn ngữ dựa trên lớp. Cả hai đều nhằm xếp hạng các phương án đầu ra theo ngữ cảnh và chỉ khảo sát chiều Nôm sang Quốc ngữ.

Nghiên cứu [15] tiếp tục hướng SMT cho chiều Nôm sang Quốc ngữ và tích hợp thêm tri thức Hán Việt. Kết quả thực nghiệm của công trình cho thấy cấu hình tích hợp đạt BLEU cao hơn cấu hình đối chiếu.

2.4.3 Ràng buộc không gian đầu ra

Trong một số bài toán, mỗi vị trí đầu ra chỉ có một số phương án hợp lệ và tập phương án này tra được từ tự điển. Khi đó, thay vì tính xác suất trên toàn bộ từ vựng đích, mô hình chỉ tính xác suất trên tập phương án của riêng vị trí đang xét. Hai bài toán dưới đây đã khai thác cách làm này.

Bài toán thứ nhất là xác định cách đọc của chữ Hán đa âm trong tiếng Trung. Mỗi chữ đa âm chỉ có một số cách đọc được ghi nhận trong tự điển, tương tự hiện tượng đa âm tự đã nêu ở Mục 2.1.1, nên tập phương án tại vị trí của chữ đó được xác định trước. Nghiên cứu [25] dùng một véc tơ

mặt nạ dựng từ tập cách đọc hợp lệ để mô hình không dự đoán sang cách đọc của chữ khác, đồng thời loại các phương án nằm ngoài tập này khỏi hàm mất mát.

Bài toán thứ hai là bộ gõ tiếng Trung, chuyển chuỗi pinyin người dùng nhập vào thành chuỗi chữ Hán. Mỗi âm tiết pinyin ứng với một tập chữ Hán có cách đọc tương ứng, nên tại mỗi bước sinh, mô hình chỉ chọn trong tập đó. Nghiên cứu [26] áp dụng ràng buộc này cả trong hàm mất mát khi huấn luyện lẫn khi sinh chuỗi.

Điểm chung của hai bài toán là tập phương án tại mỗi vị trí được xác định trước từ tự điển cách đọc, và ràng buộc được áp trực tiếp lên phân phối xác suất của mô hình thay vì xử lý ở khâu hậu kiểm.

2.4.4 Định vị nghiên cứu

Các công trình trên cho thấy NMT và SMT đều đã được áp dụng cho chuyển tự Hán/Nôm. Tuy nhiên, mô hình NMT sử dụng cùng một từ vựng đích cho mọi vị trí, còn tự điển trong SMT được dùng để bổ sung ánh xạ vào bảng cụm từ [10]. Trong phạm vi khảo sát, chưa thấy công trình nào chỉ tính xác suất đầu ra tại từng vị trí trên tập ứng viên của token nguồn tương ứng. Các nghiên cứu gần nhất về cơ chế này thuộc bài toán phân biệt cách đọc chữ đa âm và nhập Pinyin, chưa khảo sát chuyển tự Hán/Nôm hai chiều.

Bên cạnh đó, phần lớn các nghiên cứu chuyển tự được khảo sát tập trung vào chiều Nôm sang Quốc ngữ. Ở chiều từ Quốc ngữ sang Hán/Nôm, nghiên cứu [16] xây dựng hai mô hình riêng cho chữ Hán và chữ Nôm, không huấn luyện chung với chiều Hán/Nôm sang Quốc ngữ.

Từ những khoảng trống trên, khóa luận xây dựng và đánh giá họ mô hình CCT cho chuyển tự Hán/Nôm hai chiều. CCT giới hạn đầu ra tại mỗi vị trí bằng tập ứng viên và gồm hai biến thể CCT-C và CCT-D. Mỗi biến thể học chung hai chiều trong một mô hình cho mỗi hệ chữ. Đóng góp của khóa luận là cụ thể hóa và đánh giá cách áp dụng cơ chế này cho

chuyển tự Hán/Nôm, không phải đề xuất khái niệm ràng buộc không gian đầu ra. Do chưa có thí nghiệm loại bỏ riêng ràng buộc ứng viên, kết quả ở Chương 4 phản ánh hiệu quả của toàn bộ mô hình, không tách riêng ảnh hưởng của thành phần này.

Chương 3

Phương pháp

Chương này trình bày hai phương pháp thuộc họ mô hình CCT được xây dựng cho bài toán chuyển tự hai chiều giữa chữ Quốc ngữ và chữ Hán/Nôm: CCT-C (Classifier) phân loại độc lập tại từng vị trí và giải mã song song, còn CCT-D (Decoder) bổ sung bộ giải mã Transformer để mô hình hóa sự phụ thuộc giữa các ký tự đầu ra và sinh chuỗi tự hồi quy. Hai phương pháp dùng chung bộ mã hóa BERT huấn luyện từ đầu và token chỉ thị chiều chuyển tự; sau biểu diễn mã hóa H , mỗi phương pháp có khối chấm điểm và chiến lược giải mã riêng. Đầu ra của từng nhánh đều được giới hạn tại vị trí i trong tập ứng viên $\mathcal{C}(x_i)$ thay vì toàn bộ từ vựng đích. Phần còn lại của chương lần lượt trình bày hình thức hóa bài toán, token hóa dữ liệu, thành phần chung và điểm phân nhánh, chi tiết từng phương pháp, hàm mất mát cùng quy trình huấn luyện và suy luận.

Trong các bảng và phần phân tích, `vi2no` chỉ chiều chuyển tự từ Quốc ngữ sang Hán/Nôm, còn `no2vi` chỉ chiều ngược lại.


3.1 Tổng quan phương pháp

Luồng suy luận từ chuỗi nguồn đến chuỗi kết quả gồm năm bước:


1. Tiền xử lý chuỗi nguồn: tách token theo cấu hình và thêm token chỉ thị chiều chuyển tự ở đầu chuỗi.

2. Mã hóa chuỗi bằng BERT để thu được $H = (h_0, h_1, \dots, h_n)$. Đây là điểm cuối của luồng kiến trúc dùng chung.
3. Từ H , hai phương pháp tính điểm theo hai nhánh riêng:
 - CCT-C dùng MLP trên h_i và véc tơ nhúng của từng token đích;
 - CCT-D đưa H vào bộ giải mã Transformer, rồi dùng tích vô hướng giữa biểu diễn giải mã và véc tơ nhúng token đích.
4. Trong từng nhánh, mô hình chỉ lấy điểm của các token thuộc $\mathcal{C}(x_i)$ và chuẩn hóa softmax trên chính tập này.
5. CCT-C chọn token có xác suất cao nhất đồng thời tại mọi vị trí; CCT-D sinh tuần tự bằng tìm kiếm chùm tia, có điều kiện theo các token đã sinh. Các token được chọn sau đó được ghép thành chuỗi đích.

Kiến trúc tổng quan của CCT-C và CCT-D được minh họa lần lượt trong Hình 3.1 và Hình 3.2.



Hình 3.1: Kiến trúc CCT-C (Classifier).



Hình 3.2: Kiến trúc CCT-D (Decoder).

3.2 Hình thức hóa bài toán

3.2.1 Giới hạn không gian đầu ra bằng tập ứng viên

Trong dữ liệu của khóa luận, các cặp không có cùng số token được loại bỏ ở bước tiền xử lý (Chương 4); các cặp còn lại vì thế được căn chỉnh gần một đối một giữa âm tiết Quốc ngữ và ký tự Hán/Nôm. Dựa trên đặc trưng này, tại mỗi vị trí i , mô hình chỉ dự đoán token đích trong tập ứng viên $\mathcal{C}(x_i)$ thay vì sinh tự do trên toàn bộ từ vựng đích $\mathcal{V}_{\text{tgt}}$.

Về mặt hình thức, với chuỗi nguồn độ dài n :

$$x = (x_1, x_2, \dots, x_n), \quad (3.1)$$

mô hình sinh ra chuỗi đích cùng độ dài:

$$y = (y_1, y_2, \dots, y_n), \quad (3.2)$$

trong đó mỗi phần tử y_i được lựa chọn từ tập ứng viên cố định $\mathcal{C}(x_i)$ của ký tự nguồn x_i :

$$\mathcal{C}(x_i) \subseteq \mathcal{V}_{\text{tgt}} \quad (3.3)$$

thay vì được lựa chọn từ toàn bộ không gian từ vựng đích $\mathcal{V}_{\text{tgt}}$. Cách tiếp cận này thu hẹp đáng kể không gian dự đoán và khai thác trực tiếp ràng buộc ngôn ngữ học vốn có của bài toán.

3.2.2 Xây dựng tập ứng viên

Tập ứng viên $\mathcal{C}(x_i)$ được xây dựng trước khi huấn luyện từ hai nguồn:

- Dữ liệu song song của tập huấn luyện và tập phát triển: toàn bộ ánh xạ (x_i, y_i) quan sát được trong hai tập này được dùng để xây dựng từ vựng và tập ứng viên. Tập kiểm tra không tham gia vào quá trình xây dựng;

- Tự điển Hán Việt và Nôm/Quốc ngữ: đối với token nguồn chưa xuất hiện trong tập huấn luyện và tập phát triển, các ánh xạ trong tự điển được dùng để bổ sung token đó cùng tập ứng viên tương ứng.


Trong khóa luận, tập phát triển được xem là tài nguyên của giai đoạn phát triển hệ thống, dùng để hoàn thiện không gian từ vựng, tăng độ bao phủ của tập ứng viên và thực hiện dừng sớm. Tham số mô hình chỉ được cập nhật từ tập huấn luyện, còn tập kiểm tra được giữ tách biệt và chỉ dùng để báo cáo kết quả cuối cùng.

Bảng 3.1 minh họa một số tập ứng viên $\mathcal{C}(x_i)$ theo hai chiều chuyển tự trên cả hai hệ chữ.


Hệ chữ	Chiều	Token nguồn	Tập ứng viên
Hán	no2vi	比	bì, bí, bắc, bỉ, khâu, tì, tỉ, tị
Hán	no2vi	缘	bản, duyên, duyên, nhân, phản, thả
Hán	vi2no	凉	两, 俩, 凉, 琅, 谅, 谋
Hán	vi2no	化	传, 化, 华, 县, 府, 沾, 華, 货
Nôm	no2vi	筋	bạc, cân, cón, gân, khám, muông, nem, sức, trợ, động
Nôm	no2vi	绣	cát, dồ, dụ, kéo, kéo, là, rẻo, sỏi, tú, tục, xô, đọc
Nôm	vi2no	yên	瓢, 厌, 厥, 概, 淹, 闷, 阉
Nôm	vi2no	cáp	冷, 合, 吟, 哈, 怜, 恰, 蛉, 蛤, 鸽

Bảng 3.1: Một số tập ứng viên $\mathcal{C}(x_i)$ theo hai chiều chuyển tự.

Số lượng ứng viên trung bình ở chiều **vi2no** cao hơn chiều **no2vi**. Trên ngữ liệu Hán, mỗi ký tự nguồn ở chiều **vi2no** có trung bình khoảng 6.8 ứng viên, trong khi ở chiều **no2vi** là khoảng 1.5. Đối với ngữ liệu Nôm, các giá trị tương ứng lần lượt là khoảng 18.5 và 4.3. Phân bố này phù hợp với đặc điểm một âm tiết Quốc ngữ có thể được ghi bằng nhiều ký tự Hán/Nôm, trong khi một ký tự Hán/Nôm thường có ít cách đọc Quốc ngữ hơn. Phân bố số lượng ứng viên trên từng hệ chữ được minh họa ở Hình 3.3 và Hình 3.4.



Hình 3.3: Phân bố kích thước tập ứng viên trên dữ liệu Hán.



Hình 3.4: Phân bố kích thước tập ứng viên trên dữ liệu Nôm.

Bảng 3.2 tổng hợp các thống kê về kích thước tập ứng viên trên bốn cấu hình chuyển tự. Ngoài số lượng ứng viên trung bình và trung vị, tỉ lệ ký tự nguồn chỉ có một ứng viên duy nhất (cột “% đơn trị”) phản ánh mức độ nhập nhằng của từng chiều chuyển tự. Các trường hợp đơn trị không yêu cầu mô hình phân biệt giữa nhiều phương án đầu ra.

Chiều no2vi trên ngữ liệu Hán có tỉ lệ đơn trị cao nhất (68.3%), trong khi chiều vi2no trên ngữ liệu Nôm chỉ đạt 15.4%. Theo thống kê tập ứng viên, chiều từ Quốc ngữ sang Hán/Nôm vì vậy nhập nhằng hơn chiều ngược lại, đặc biệt trên hệ chữ Nôm. Mối liên hệ giữa thống kê này và kết quả được xem xét trong Chương 4.

Bảng cũng ghi nhận một số trường hợp có số lượng ứng viên rất lớn. Chẳng hạn, trên ngữ liệu Nôm ở chiều no2vi, một ký tự có thể tương ứng

với tối đa 422 ứng viên. Mức đa trị cao làm tăng số phương án cần phân biệt; tuy nhiên, kích thước tập ứng viên không phải yếu tố duy nhất quyết định độ khó của từng mẫu, vì kết quả còn phụ thuộc vào ngữ cảnh và phân bố dữ liệu huấn luyện.

Hệ chữ	Chiều	Trung bình	Trung vị	Lớn nhất	% đơn trị
Hán	no2vi	1.48	1	127	68.3
Hán	vi2no	6.82	5	146	21.5
Nôm	no2vi	4.30	2	422	47.9
Nôm	vi2no	18.45	8	318	15.4

Bảng 3.2: Thống kê kích thước tập ứng viên.

Trong quá trình xây dựng tập ứng viên, nếu một ký tự nguồn có nhiều ký tự đích tương ứng thì toàn bộ các khả năng quan sát được đều được đưa vào tập ứng viên. Ngược lại, nếu ký tự không xuất hiện trong cả ngữ liệu và tự điển, ký tự đó được ánh xạ thành [UNK] ở đầu vào và vị trí tương ứng bị loại khỏi hàm mất mát. Khi suy luận, hệ thống giữ lại token nguồn gốc thay vì yêu cầu mô hình chọn một ứng viên không tồn tại; quy trình chi tiết được trình bày ở Mục 3.8.

3.2.3 Mô hình xác suất

Tại vị trí i , mô hình tra tập $\mathcal{C}(x_i)$ của token nguồn x_i và chỉ tính điểm cho các token trong tập này. Ký hiệu $s_i(v)$ là điểm thô mà nhánh đang xét gán cho ứng viên v . Xác suất của một token đích được định nghĩa bởi

$$p_{\theta}(y_i = v \mid x, y_{<i}, d) = \begin{cases} \frac{\exp(s_i(v))}{\sum_{u \in \mathcal{C}(x_i)} \exp(s_i(u))}, & v \in \mathcal{C}(x_i), \\ 0, & v \notin \mathcal{C}(x_i). \end{cases} \quad (3.4)$$

Trong đó, d là chiều chuyển tự và $y_{<i} = (y_1, \dots, y_{i-1})$ là dãy token đích trước vị trí i . Với CCT-C, $s_i(v)$ do MLP tính từ h_i và véc tơ nhúng của v ; dự đoán không phụ thuộc trực tiếp vào $y_{<i}$, nên về điều kiện rút gọn thành (x, d) . Với CCT-D, $s_i(v)$ là tích vô hướng giữa biểu diễn của bộ giải mã và véc tơ nhúng của v ; biểu diễn này phụ thuộc vào x , d và $y_{<i}$.

Để xử lý đồng thời nhiều câu trong một lô (batch), các danh sách ứng viên được đệm đến cùng độ dài. Mặt nạ chỉ loại những ô được thêm vào khi đệm, không dùng để che toàn bộ từ vựng. Vì vậy, mô hình chỉ tạo điểm cho các ứng viên và tổng ở mẫu số của Công thức (3.4) chỉ chạy trên $\mathcal{C}(x_i)$.

3.3 Token hóa dữ liệu

3.3.1 Token hóa ở cấp ký tự

Trong dữ liệu được khảo sát, mỗi chữ Hán hoặc chữ Nôm thường tương ứng với một âm tiết Quốc ngữ, còn các cặp câu giữ cân chỉnh gần một đối một. Vì vậy, tách token ở cấp ký tự phù hợp trực tiếp với đơn vị chuyển tự, thay cho cơ chế WordPiece được sử dụng trong BERT [17].

Tách ở cấp ký tự bảo toàn đơn vị chuyển tự (mỗi token ứng với một ký tự hoặc một âm tiết) và duy trì cân chỉnh gần một đối một giữa chuỗi nguồn và chuỗi đích. Cách tách này cũng đơn giản hóa việc xây dựng tập ứng viên, do mỗi token nguồn chỉ có một tập ứng viên cố định, đồng thời phù hợp với cơ chế lựa chọn token đích có ràng buộc tại từng vị trí.

3.3.2 Cụm từ cố định

Trong cấu hình tích hợp cụm từ, bảng cụm từ cố định được sử dụng ở bước tiền xử lý trước khi xây dựng từ vựng và mẫu huấn luyện. Các đoạn tương ứng gồm nhiều đơn vị ở hai phía được gộp thành một token, qua đó bổ sung các token cụm từ vào từ vựng của mô hình mà vẫn duy trì quan

hệ cân chỉnh giữa chuỗi nguồn và chuỗi đích.

Việc sử dụng bảng cụm từ không thay thế tự điển. Trong cấu hình này, tự điển vẫn được dùng để mở rộng tập ứng viên, còn bảng cụm từ bổ sung cách xử lý cho các chuỗi nhiều token.

Mỗi mục trong bảng cụm từ gồm một chuỗi âm tiết Quốc ngữ và chuỗi ký tự Hán/Nôm tương ứng. Chỉ những cặp có cùng số đơn vị ở hai phía mới được sử dụng. Khi một cặp cụm xuất hiện trong ngữ liệu, các đơn vị tương ứng ở cả chuỗi nguồn và chuỗi đích được gộp đồng thời thành một token, nhờ đó số token ở hai phía vẫn bằng nhau. Cụm từ tiếng Việt được nối bằng dấu gạch dưới (_), còn cụm từ Hán/Nôm được bao bởi cặp ký hiệu | |. Các đơn vị không thuộc cụm được giữ nguyên thành những token riêng biệt.

Ví dụ, câu:

nam quốc sơn hà nam đế cư
được tách thành

[nam_quốc], [sơn_hà], [nam], [đế], [cư]

và chuỗi Hán tương ứng được biểu diễn dưới dạng

[| 南國 |], [| 山河 |], [南], [帝], [居].

Cả hai chuỗi đều gồm năm token, do đó vẫn duy trì được quan hệ cân chỉnh gần một đối một giữa nguồn và đích. Khi không sử dụng cụm từ cố định, câu trên được tách thành bảy token. Các ký hiệu gộp cho phép khôi phục chuỗi đơn vị ban đầu một cách xác định.

3.3.3 Tập từ vựng thống nhất

Để xử lý cả hai chiều chuyển tự trong cùng một mô hình, khóa luận xây dựng một tập từ vựng bao phủ cả token tiếng Việt lẫn token Hán/Nôm. Do không tồn tại mô hình BERT huấn luyện sẵn có không gian từ vựng

tương thích với hệ chữ này, bộ mã hóa được huấn luyện từ đầu thay vì tinh chỉnh từ các trọng số tiền huấn luyện. Cấu trúc của tập từ vựng được trình bày trong Bảng 3.3.

ID	Token	Mô tả
0	[PAD]	Token đệm (padding).
1	[UNK]	Token ngoài từ vựng (out-of-vocabulary).
2	[vi2no]	Chiều chuyển tự Quốc ngữ $\rightarrow$ Hán/Nôm.
3	[no2vi]	Chiều chuyển tự Hán/Nôm $\rightarrow$ Quốc ngữ.
$4 \dots 3+V$	<vi>	Các token tiếng Việt (ký tự hoặc cụm từ).
$4+V \dots 3+V+N$	<no>	Các token Hán/Nôm (ký tự hoặc cụm từ).

Bảng 3.3: Cấu trúc tập từ vựng thống nhất.

Trong đó, V là số lượng token tiếng Việt và N là số lượng token Hán/Nôm trong từ vựng. Tùy theo cấu hình thực nghiệm, mỗi tập có thể bao gồm cả token đơn ký tự và token cụm từ. Token chỉ thị chiều chuyển tự luôn được đặt ở đầu chuỗi đầu vào, để cùng một mô hình xử lý được cả hai chiều chuyển tự mà không cần xây dựng các kiến trúc riêng biệt. Riêng CCT-D sử dụng một véc tơ BOS học được độc lập, không phải một token trong từ vựng thống nhất. Mô hình không cần token EOS vì số vị trí đầu ra được cố định bằng số token nguồn sau tiền xử lý.

3.4 Thành phần chung và điểm phân nhánh

3.4.1 Các thành phần chính

Hình 3.1 và Hình 3.2 minh họa hai kiến trúc. Luồng chung kết thúc tại H : CCT-C chuyển từng h_i vào MLP, còn CCT-D đưa H vào bộ giải mã Transformer. Hai nhánh đều sử dụng bảng nhúng đầu ra theo chiều chuyển tự và giới hạn kết quả trong $\mathcal{C}(x_i)$, nhưng thực hiện chấm điểm và giải mã theo cách riêng ở Mục 3.5 và Mục 3.6.

3.4.2 Bộ mã hóa BERT

Hai chiều chuyển tự sử dụng chung một bộ mã hóa BERT. Với chuỗi đầu vào

$$x = ([\text{dir}], x_1, x_2, \dots, x_n),$$

trong đó $[\text{dir}] \in \{[\text{vi2no}], [\text{no2vi}]\}$ là token chỉ thị chiều chuyển tự, bộ mã hóa sinh ra chuỗi biểu diễn ngữ cảnh

$$H = (h_0, h_1, \dots, h_n), \quad h_i \in \mathbb{R}^{d_{\text{model}}}. \quad (3.5)$$

Trong đó, h_0 là biểu diễn của token chỉ thị chiều chuyển tự, còn h_i ($i \geq 1$) là biểu diễn ngữ cảnh của token x_i , được tổng hợp từ toàn bộ chuỗi đầu vào thông qua cơ chế tự chú ý hai chiều.

Token chỉ thị chiều chuyển tự quyết định tác vụ mà mô hình thực hiện. Khi token đầu vào là $[\text{vi2no}]$, mô hình học ánh xạ từ Quốc ngữ sang Hán/Nôm; ngược lại, với $[\text{no2vi}]$, mô hình thực hiện chuyển tự từ Hán/Nôm sang Quốc ngữ. Cùng một bộ tham số vì vậy xử lý được cả hai chiều chuyển tự mà không cần dựng hai mô hình riêng.

Thiết kế này là một dạng học đa nhiệm (multi-task learning) [27] phù hợp với bài toán chuyển tự Hán/Nôm. Hai chiều chuyển tự biểu diễn cùng một quan hệ tương ứng giữa chữ viết và âm đọc, nên việc dùng chung tham số tạo điều kiện để tri thức học được ở một chiều hỗ trợ chiều còn lại. Trong điều kiện ngữ liệu song song hạn chế và mô hình phải huấn luyện từ đầu, huấn luyện chung hai chiều làm tăng lượng tín hiệu giám sát trên cùng một bộ tham số và được kỳ vọng hỗ trợ khả năng khái quát. Bộ mã hóa chung cùng tập từ vựng thống nhất cũng đưa token Hán/Nôm và Quốc ngữ vào cùng một không gian biểu diễn, tạo điều kiện chia sẻ đặc trưng giữa hai chiều. Mức đóng góp thực tế của cơ chế học chung được đối chiếu bằng thực nghiệm ở Mục 4.4.2.

3.4.3 Bảng nhúng đầu ra

Mặc dù hai chiều chuyển tự sử dụng chung một bộ mã hóa BERT, không gian từ vựng đích của mỗi chiều lại khác nhau, nên cần hai bảng nhúng đầu ra độc lập:

$$E_{\text{vi2no}}^{\text{out}} \in \mathbb{R}^{|\mathcal{V}_{\text{no}}| \times d_{\text{model}}}, \quad E_{\text{no2vi}}^{\text{out}} \in \mathbb{R}^{|\mathcal{V}_{\text{vi}}| \times d_{\text{model}}}. \quad (3.6)$$

trong đó $\mathcal{V}_{\text{no}}$ và $\mathcal{V}_{\text{vi}}$ lần lượt là từ vựng đích Hán/Nôm và từ vựng đích Quốc ngữ. Mỗi hàng của bảng nhúng tương ứng với một token đích và có cùng số chiều d_{model} với biểu diễn của bộ mã hóa và bộ giải mã. Hai bảng nhúng này được sử dụng trong cả CCT-C và CCT-D để tính điểm các ứng viên ở từng vị trí.

3.4.4 Ràng buộc theo tập ứng viên

Cả CCT-C và CCT-D đều sử dụng cơ chế ràng buộc đã được hình thức hóa ở Mục 3.2.3. Tại vị trí i , mô hình tra danh sách $\mathcal{C}(x_i)$, tính điểm từng phần tử trong danh sách và chuẩn hóa softmax trên các điểm này. Tập ứng viên được xây dựng từ ngữ liệu song song kết hợp với tự điển, như đã trình bày ở Mục 3.2.2.

Với cơ chế này, mô hình chỉ phải phân biệt giữa các ứng viên hợp lệ thay vì lựa chọn trên toàn bộ từ vựng đích. Mọi dự đoán đều bị giới hạn trong tập ứng viên của ký tự nguồn, nên mô hình không thể sinh token nằm ngoài tập này. Ràng buộc không bảo đảm token được chọn luôn đúng trong ngữ cảnh, vì mô hình vẫn có thể chọn nhầm giữa các ứng viên hợp lệ.

3.5 CCT-C: Phân loại cục bộ

3.5.1 Bộ chấm điểm

CCT-C tạo chuỗi chuyển tự bằng cách lựa chọn độc lập token đích tại từng vị trí. Tại vị trí i , lựa chọn được giới hạn trong tập ứng viên $\mathcal{C}(x_i)$. Bộ mã hóa BERT cung cấp biểu diễn ngữ cảnh h_i , còn mỗi ứng viên $v \in \mathcal{C}(x_i)$ được biểu diễn bởi véc tơ nhúng đầu ra E_v^{out} . Bộ chấm điểm học một hàm đánh giá mức độ phù hợp giữa hai biểu diễn này để xác định ứng viên đầu ra.

CCT-C dùng một MLP hai lớp để biến cặp biểu diễn thành điểm số. Trước hết, mô hình nối biểu diễn ngữ cảnh h_i (Công thức (3.5)) với véc tơ nhúng của ứng viên E_v^{out} (Công thức (3.6)):

$$u_{i,v} = [h_i; E_v^{\text{out}}] \in \mathbb{R}^{2d_{\text{model}}}. \quad (3.7)$$

Véc tơ nối được chiếu về không gian ẩn, đưa qua GELU và Dropout:

$$g_{i,v} = \text{Dropout}(\text{GELU}(W_1 u_{i,v} + b_1)) \in \mathbb{R}^{d_{\text{model}}}. \quad (3.8)$$

Lớp tuyến tính thứ hai biến biểu diễn ẩn thành một điểm vô hướng cho ứng viên:

$$\text{score}_i^{\text{CCT-C}}(v) = W_2 g_{i,v} + b_2 \in \mathbb{R}. \quad (3.9)$$

Trong đó, $[\cdot; \cdot]$ ký hiệu phép nối hai véc tơ; $W_1 \in \mathbb{R}^{d_{\text{model}} \times 2d_{\text{model}}}$ chiếu véc tơ $2d_{\text{model}}$ chiều về không gian d_{model} chiều, còn $W_2 \in \mathbb{R}^{1 \times d_{\text{model}}}$ sinh ra một giá trị vô hướng làm điểm số của ứng viên. Trong đó, $b_1 \in \mathbb{R}^{d_{\text{model}}}$ là véc tơ độ chệch, còn $b_2 \in \mathbb{R}$ là độ chệch vô hướng.

Khác với phép tích vô hướng đơn thuần, MLP cho phép học các tương tác phi tuyến giữa biểu diễn ngữ cảnh của token nguồn và đặc trưng của từng ứng viên. Khả năng này được kỳ vọng hỗ trợ phân biệt các ứng viên gần nhau trong những trường hợp đa trị.

Các tham số W_1 , W_2 , b_1 và b_2 được chia sẻ giữa hai chiều chuyển tự; chỉ bằng nhúng đầu ra E^{out} thay đổi tương ứng với chiều chuyển tự và được cập nhật cùng toàn bộ mô hình trong quá trình huấn luyện.

3.5.2 Giải mã song song

Sau khi tính điểm cho các ứng viên, CCT-C lựa chọn token có điểm cao nhất tại mỗi vị trí:

$$\hat{y}_i = \arg \max_{v \in \mathcal{C}(x_i)} \text{score}_i^{\text{CCT-C}}(v), \quad i = 1, \dots, n. \quad (3.10)$$

Do điểm số tại vị trí i phụ thuộc vào h_i nhưng không phụ thuộc trực tiếp vào các token đích đã dự đoán ở vị trí khác, các dự đoán là độc lập có điều kiện theo chuỗi nguồn x và chiều chuyển tự d . Lưu ý rằng h_i vẫn tổng hợp ngữ cảnh của toàn bộ chuỗi nguồn nhờ cơ chế tự chú ý hai chiều. Vì vậy, toàn bộ chuỗi được giải mã trong một lần truyền xuôi sau khi bộ mã hóa hoàn tất, không cần quá trình sinh tự hồi quy như các mô hình giải mã Transformer. Cách xử lý các token ngoài từ vựng được trình bày thống nhất ở Mục 3.8.

3.6 CCT-D: Giải mã tự hồi quy

3.6.1 Kiến trúc bộ giải mã

Khác với CCT-C chỉ sử dụng bộ mã hóa BERT để phân loại độc lập tại từng vị trí, CCT-D bổ sung một bộ giải mã Transformer để mô hình hóa sự phụ thuộc giữa các token đầu ra. Bộ giải mã lấy biểu diễn của bộ mã hóa làm ngữ cảnh nguồn và dùng các token đích đã sinh ở những bước trước để xây dựng biểu diễn cho vị trí hiện tại theo cơ chế tự hồi quy. Biểu diễn này sau đó được dùng để chấm điểm các ứng viên trong tập $\mathcal{C}(x_i)$.

Bộ giải mã gồm N_d lớp Transformer sử dụng kiến trúc Pre-LayerNorm (Pre-LN) [21], trong đó phép chuẩn hóa lớp được áp dụng trước mỗi mô-đun

con thay vì sau như kiến trúc Post-LayerNorm ban đầu [20]. Với thiết kế này, gradient lan truyền ổn định hơn và các mô hình nhiều lớp dễ huấn luyện hơn.

Mỗi lớp của bộ giải mã gồm ba mô-đun con theo thứ tự. Đầu tiên là tự chú ý có mặt nạ (masked self-attention): mỗi vị trí t chỉ được chú ý tới các vị trí $\leq t$, để mô hình dùng được thông tin từ các token đích đã sinh mà vẫn bảo đảm tính nhân quả của quá trình giải mã. Kế đến, chú ý chéo (cross-attention) lấy chuỗi biểu diễn của bộ mã hóa $H = (h_0, \dots, h_n)$ làm bộ nhớ (memory), để bộ giải mã chọn lọc thông tin từ chuỗi nguồn ở mỗi bước sinh. Cuối cùng, mạng truyền xuôi (feed-forward network) là một mạng MLP hai lớp với hàm kích hoạt GELU, áp dụng độc lập tại từng vị trí để tăng khả năng biểu diễn phi tuyến.

Mỗi mô-đun con đều được bao bởi kết nối dư (residual connection) theo cấu trúc Pre-LN, như đã trình bày ở Công thức (2.9).

3.6.2 Đầu vào và ép giáo viên

Do CCT-D thực hiện giải mã theo cơ chế tự hồi quy, đầu vào của bộ giải mã ở mỗi bước cần bao gồm các token đích đã sinh trước đó. Trong quá trình huấn luyện, khóa luận sử dụng kỹ thuật ép giáo viên (teacher forcing) [22], trong đó tại bước t , bộ giải mã nhận token đúng ở vị trí $t - 1$ thay vì token do chính mô hình sinh ra.

Để tránh nhầm với ký hiệu d chỉ chiều chuyển tự, gọi $a = (a_1, \dots, a_n)$ là chuỗi véc tơ đầu vào của bộ giải mã. Phép dịch phải trong ép giáo viên được viết theo từng vị trí:

$$a_t = \begin{cases} e_{\text{BOS}}, & t = 1, \\ E_{y_{t-1}^*}^{\text{out}}, & 2 \leq t \leq n. \end{cases} \quad (3.11)$$

trong đó $e_{\text{BOS}} \in \mathbb{R}^{d_{\text{model}}}$ là véc tơ nhúng học được biểu diễn ký hiệu bắt đầu chuỗi (Beginning of Sequence, BOS), còn $E_{y_{t-1}^*}^{\text{out}}$ là véc tơ nhúng của nhãn

đúng ở vị trí liền trước.

Trước khi đưa vào bộ giải mã, mỗi véc tơ đầu vào được cộng với véc tơ nhúng chiều chuyển tự và mã hóa vị trí hình sin:

$$\tilde{a}_t = (a_t + e_{\text{dir}})\sqrt{d_{\text{model}}} + \text{PE}_t, \quad (3.12)$$

trong đó e_{dir} là véc tơ nhúng biểu diễn chiều chuyển tự, PE_t là mã hóa vị trí hình sin (Công thức (2.1)) tại bước t , còn hệ số $\sqrt{d_{\text{model}}}$ điều chỉnh thang độ lớn của tổng véc tơ nhúng token và véc tơ chiều chuyển tự trước khi cộng với mã hóa vị trí.

Chuỗi sau khi nhúng được đưa qua bộ giải mã cùng với biểu diễn nguồn H :

$$(\text{dec_out}_1, \dots, \text{dec_out}_n) = \text{Decoder}(\tilde{a}_{1:n}, H; M_{\text{causal}}), \quad (3.13)$$

trong đó M_{causal} là mặt nạ nhân quả và $\text{dec_out}_t \in \mathbb{R}^{d_{\text{model}}}$ là biểu diễn dùng để chấm điểm ứng viên tại bước t . Công thức này tóm lược các lớp self-attention, cross-attention và FFN đã mô tả ở mục trước.

Ép giáo viên làm quá trình huấn luyện hội tụ nhanh và ổn định hơn, vì bộ giải mã luôn nhận được các token đích đúng ở những bước trước. Tuy nhiên, điều này cũng dẫn tới hiện tượng thiên lệch phơi nhiễm (exposure bias) [23]: trong huấn luyện, đầu vào là nhãn đúng, trong khi ở giai đoạn suy luận đầu vào lại là các token do chính mô hình sinh ra. Khóa luận chấp nhận hạn chế này để đổi lấy quá trình huấn luyện đơn giản và hiệu quả.

3.6.3 Chấm điểm bằng tích vô hướng

Khác với CCT-C sử dụng một mạng MLP để chấm điểm ứng viên, CCT-D tính điểm trực tiếp bằng tích vô hướng giữa biểu diễn của bộ giải mã và véc tơ nhúng của từng ứng viên.

Sau khi đi qua bộ giải mã, tại bước t thu được biểu diễn

$$\text{dec_out}_t \in \mathbb{R}^{d_{\text{model}}},$$

mô tả ngữ cảnh của vị trí cần dự đoán. Với mỗi ứng viên $v \in \mathcal{C}(x_t)$, bảng nhúng đầu ra cung cấp véc tơ biểu diễn $E_v^{\text{out}} \in \mathbb{R}^{d_{\text{model}}}$. Điểm số của ứng viên được tính bằng tích vô hướng giữa hai véc tơ:

$$\text{score}_t^{\text{CCT-D}}(v) = \text{dec_out}_t^\top E_v^{\text{out}} = \sum_{k=1}^{d_{\text{model}}} \text{dec_out}_{t,k} E_{v,k}^{\text{out}}. \quad (3.14)$$

Giá trị tích vô hướng càng lớn thì điểm tương thích giữa biểu diễn của bộ giải mã và véc tơ nhúng ứng viên càng cao. Khác với độ tương đồng cosine, điểm này phụ thuộc cả góc và độ lớn của hai véc tơ.

Cần phân biệt tổng trong Công thức (3.14) với điểm của cả câu. Tổng theo $k = 1, \dots, d_{\text{model}}$ chỉ cộng các thành phần của hai véc tơ để tạo một điểm vô hướng cho ứng viên v tại bước t ; đây chưa phải điểm tích lũy của chuỗi. Các điểm ứng viên tại bước này được chuẩn hóa thành log-xác suất trước khi cập nhật điểm chuỗi trong tìm kiếm chùm tia.

Biểu diễn dec_out_t đã tổng hợp thông tin từ cả chuỗi nguồn (thông qua cross-attention) và các token đích trước đó (thông qua masked self-attention). CCT-D vì vậy sử dụng trực tiếp tích vô hướng với bảng nhúng đầu ra để chấm điểm ứng viên, thay vì bổ sung bộ phân loại phi tuyến như CCT-C.

Tương tự CCT-C, CCT-D vẫn áp dụng ràng buộc tập ứng viên trước khi chuẩn hóa softmax. Dù bộ giải mã hoạt động tự hồi quy, mô hình vẫn không sinh tự do trên toàn bộ từ vựng mà chỉ chọn trong tập ứng viên $\mathcal{C}(x_t)$ của vị trí tương ứng.

Phép chấm điểm này kế thừa lớp đầu ra của Transformer. Trong Transformer gốc [20], logit được tính bằng tích vô hướng với từng hàng của ma trận chiếu trên toàn bộ từ vựng đích. CCT-D chỉ lấy các hàng tương ứng

với $\mathcal{C}(x_t)$ để tính điểm và chuẩn hóa softmax; bảng nhúng đầu ra được tách theo chiều chuyển tự, còn chuỗi được sinh đúng n bước theo độ dài nguồn.

3.6.4 Tìm kiếm chùm tia

Ở giai đoạn suy luận, CCT-D sử dụng tìm kiếm chùm tia (beam search) với kích thước chùm K để xấp xỉ lời giải tối ưu cho toàn bộ chuỗi đầu ra. Tại mỗi bước giải mã, thuật toán duy trì đồng thời K giả thuyết có điểm cao nhất. Mỗi giả thuyết lưu chuỗi token đã sinh và điểm tích lũy tương ứng.

Tại bước t , với tập ứng viên $\mathcal{C}(x_t) = \{c_1, \dots, c_C\}$, quá trình giải mã diễn ra như sau:

1. Chạy bộ giải mã trên chuỗi token hiện tại của từng giả thuyết để thu được biểu diễn tại vị trí cuối $\text{dec_out}_t^{(k)}$;
2. Tính log xác suất trên tập ứng viên. Với $q_{k,r} = (\text{dec_out}_t^{(k)})^\top E_{c_r}^{\text{out}}$:

$$\log p(c_r \mid \text{hyp}_k, x, d) = q_{k,r} - \log \sum_{\ell=1}^C \exp(q_{k,\ell}), \quad r = 1, \dots, C;$$

3. Cập nhật điểm của từng giả thuyết mở rộng:

$$\text{score}_{k,c} = s_k + \log p(c \mid \text{hyp}_k),$$

trong đó s_k là điểm tích lũy hiện tại của giả thuyết thứ k ;

4. Giữ lại K giả thuyết có điểm cao nhất để tiếp tục giải mã ở bước tiếp theo.

Sau n bước, điểm của một chuỗi giả thuyết $y = (y_1, \dots, y_n)$ là

$$S(y) = \sum_{t=1}^n \log p_\theta(y_t \mid x, y_{<t}, d). \quad (3.15)$$

Giả thuyết có $S(y)$ lớn nhất được chọn làm kết quả cuối cùng. Đây là tổng log-xác suất theo các vị trí, không phải tổng trực tiếp các điểm tích vô hướng trong Công thức (3.14). Không cần chuẩn hóa theo độ dài vì mọi giả thuyết đều có đúng n token và được so sánh sau cùng số bước.

3.7 Huấn luyện

3.7.1 Hàm mất mát

Cả CCT-C và CCT-D đều được huấn luyện bằng cách tối thiểu hóa hàm mất mát entropy chéo (cross-entropy), tương đương với cực đại hóa log hợp lý (log-likelihood), trên tập các vị trí hợp lệ

$$\mathcal{I} = \{i \mid x_i \neq [\text{PAD}], \mathcal{C}(x_i) \neq \emptyset, y_i^* \in \mathcal{C}(x_i)\}. \quad (3.16)$$

Các vị trí đệm, vị trí không có ứng viên hoặc vị trí có nhãn đích nằm ngoài tập ứng viên không tham gia vào hàm mất mát.

$$\mathcal{L}(x, y^*) = -\frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \log p_\theta(y_i^* \mid x, y_{<i}^*, d). \quad (3.17)$$

Trong đó, xác suất được tính theo Công thức (3.4). Đối với CCT-C, thành phần $y_{<i}^*$ được lược bỏ; đối với CCT-D, xác suất còn phụ thuộc vào các token đích đúng ở những vị trí trước thông qua cơ chế ép giáo viên.

Mất mát cục bộ tại vị trí i được xác định bởi

$$\ell_i = -s_i(y_i^*) + \log \sum_{v' \in \mathcal{C}(x_i)} \exp(s_i(v')), \quad i \in \mathcal{I}. \quad (3.18)$$

Khi đó, mất mát của một cặp câu là trung bình trên các vị trí hợp lệ:

$$\mathcal{L}(x, y^*) = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \ell_i. \quad (3.19)$$

Trong Công thức (3.18), $s_i(\cdot)$ được tính theo Công thức (3.9) đối với CCT-C hoặc Công thức (3.14) đối với CCT-D. Biểu thức này tương đương Công thức (3.17); cách viết tách theo vị trí chỉ làm rõ hai thành phần của entropy chéo.

Biểu thức trên cho thấy mô hình tối ưu điểm của nhãn đúng tương đối với đại lượng log-sum-exp của toàn bộ ứng viên trong $\mathcal{C}(x_i)$. Nhờ ràng buộc tập ứng viên, quá trình học chỉ tập trung phân biệt giữa các ứng viên hợp lệ thay vì toàn bộ từ vựng đích.

3.7.2 Quy trình huấn luyện

Quy trình huấn luyện của hai phương pháp CCT được tóm tắt như sau. Với mỗi cặp dữ liệu huấn luyện (x, y^*) , mô hình được tối ưu theo các bước sau:

1. Mã hóa chuỗi nguồn: chuỗi đầu vào được đưa qua bộ mã hóa BERT để thu được biểu diễn ngữ cảnh $H = (h_0, h_1, \dots, h_n)$.
2. Tính điểm ứng viên: CCT-C dùng trực tiếp biểu diễn h_i của từng vị trí để tính điểm các ứng viên trong $\mathcal{C}(x_i)$ bằng bộ chấm điểm MLP; CCT-D xây dựng đầu vào bộ giải mã theo kỹ thuật ép giáo viên (Công thức (3.11)), rồi dùng biểu diễn của bộ giải mã để tính điểm các ứng viên bằng tích vô hướng với bảng nhúng đầu ra.
3. Chuẩn hóa điểm của các phần tử trong $\mathcal{C}(x_i)$ bằng softmax để thu được phân phối xác suất tại vị trí i .
4. Tính hàm mất mát entropy chéo trên các vị trí hợp lệ theo Công thức (3.17).
5. Cập nhật tham số: gradient được lan truyền ngược qua toàn bộ mô hình, cập nhật tham số của bộ mã hóa BERT, bộ chấm điểm (CCT-C) hoặc bộ giải mã Transformer (CCT-D), cùng các bảng nhúng.

3.8 Suy luận

Quy trình tiền xử lý khi suy luận phụ thuộc vào cấu hình cụm từ. Ở cấu hình không dùng cụm từ, các token đơn trong chuỗi đầu vào được giữ nguyên. Ở cấu hình tích hợp cụm từ, các cụm đã được bổ sung vào từ vựng trước quá trình huấn luyện được nhận dạng và gộp trước khi đưa vào mô hình. Cấu hình hậu xử lý cũng không gộp token đầu vào; sau khi giải mã, bảng cụm từ được đối sánh trên chuỗi nguồn để thay thế các đoạn đầu ra tương ứng.

3.8.1 Gộp cụm từ

Bước gộp cụm chỉ được thực hiện ở cấu hình tích hợp cụm từ, trong đó các token cụm đã có trong từ vựng của mô hình. Chuỗi đầu vào được quét từ trái sang phải theo chiến lược khớp dài nhất (longest matching):

1. Tại mỗi vị trí i , tìm cụm từ dài nhất bắt đầu tại i có trong bảng cụm từ và từ vựng của mô hình;
2. Nếu tìm thấy, gộp toàn bộ cụm thành một token duy nhất (`a_b_c` đối với tiếng Việt hoặc `|ABC|` đối với Hán/Nôm), sau đó tiếp tục tại vị trí kế tiếp của cụm;
3. Nếu không tìm thấy, giữ nguyên token hiện tại và chuyển sang vị trí kế tiếp.

Chiến lược này ưu tiên cụm dài hơn và chỉ gộp những cụm có trong từ vựng được xây dựng cho cấu hình tích hợp. Hai cấu hình còn lại bỏ qua toàn bộ bước này.

3.8.2 Suy luận với CCT-C

Sau tiền xử lý, CCT-C mã hóa chuỗi bằng BERT rồi giải mã song song theo Mục 3.5.2: MLP chấm điểm và chọn ứng viên tốt nhất tại mọi vị trí đồng thời, không cần vòng lặp tự hồi quy.

3.8.3 CCT-D: Tìm kiếm chùm tia

Khác với CCT-C, CCT-D sinh chuỗi đầu ra theo cơ chế tự hồi quy: sau khi mã hóa chuỗi nguồn, chùm tia được khởi tạo với một giả thuyết duy nhất dùng véc tơ BOS học được e_{BOS} và điểm tích lũy bằng 0, sau đó các giả thuyết được mở rộng qua n bước theo thuật toán trình bày ở Mục 3.6.4, và giả thuyết có điểm tích lũy cao nhất được chọn làm kết quả cuối cùng. So với giải mã tham lam (greedy decoding), việc duy trì đồng thời K chuỗi giả thuyết làm giảm nguy cơ loại bỏ quá sớm một chuỗi có điểm tức thời thấp hơn nhưng có thể đạt tổng điểm chuỗi cao hơn ở các bước sau.

3.8.4 Xử lý token ngoài từ vựng

Các token không xuất hiện trong từ vựng thống nhất được ánh xạ thành [UNK] ở đầu vào, đồng thời token gốc được lưu lại để phục hồi sau suy luận. Do không tồn tại tập ứng viên tương ứng, mô hình không thực hiện dự đoán tại các vị trí này và loại chúng khỏi hàm mất mát trong pha huấn luyện.

Cách xử lý như sau:

- Không chấm điểm hoặc dự đoán token đích tại vị trí OOV;
- Token gốc được giữ nguyên trong chuỗi đầu ra để bảo toàn thông tin;
- Đối với CCT-D, khi vị trí OOV được đưa vào chuỗi đầu vào của bước giải mã kế tiếp, véc tơ nhúng token tương ứng được thay bằng

0; véc tơ chiều chuyển tự và mã hóa vị trí vẫn được cộng theo Công thức (3.12).

3.8.5 Tổng hợp đầu ra

Sau khi hoàn tất quá trình giải mã, chuỗi token dự đoán được chuyển về dạng văn bản theo ba bước:

1. Tra cứu token tương ứng từ chỉ số dự đoán; đối với các vị trí OOV, giữ nguyên token đầu vào;
2. Ở cấu hình tích hợp cụm từ, thực hiện tách token đảo ngược (detokenization): các token cụm (`|ABC|` hoặc `a_b_c`) được khôi phục về chuỗi ký tự hoặc chuỗi từ ban đầu;
3. Ghép các token theo đúng thứ tự để tạo thành chuỗi chuyển tự cuối cùng.

3.9 Tóm tắt chương

Chương này đã trình bày họ mô hình Candidate-Constrained Transliteration (CCT) được xây dựng trong khóa luận, gồm hai biến thể CCT-C và CCT-D. Trên cơ sở đặc trưng căn chỉnh gần một đối một của bài toán chuyển tự giữa chữ Hán/Nôm và chữ Quốc ngữ, khóa luận áp dụng ràng buộc tập ứng viên để thu hẹp không gian dự đoán tại từng vị trí, kết hợp với một bộ mã hóa BERT dùng chung cho cả hai chiều chuyển tự.

Hai phương pháp khác nhau ở cơ chế chấm điểm và giải mã. CCT-C thực hiện phân loại cục bộ và giải mã song song trên toàn bộ chuỗi đầu ra, trong khi CCT-D bổ sung bộ giải mã Transformer để mô hình hóa sự phụ thuộc giữa các token đích và sử dụng tìm kiếm chùm tia trong pha suy luận. Cả hai đều dùng chung cơ chế ràng buộc tập ứng viên, bảo đảm mỗi token đầu ra luôn thuộc tập ứng viên đã xây dựng cho token nguồn tương ứng.

Chương tiếp theo trình bày thiết lập thực nghiệm, các bộ dữ liệu sử dụng, tiêu chí đánh giá và kết quả so sánh hai phương pháp CCT với các mô hình cơ sở, kèm phân tích ảnh hưởng của tập ứng viên và các cấu hình cụm từ cố định đối với chất lượng chuyển tự.

Chương 4

Thực nghiệm

Chương này đánh giá hai phương pháp CCT trên ngữ liệu Hán và Nôm. Sau phần mô tả dữ liệu, độ đo và thiết lập huấn luyện, các kết quả được phân tích theo bốn câu hỏi: CCT-C và CCT-D khác mô hình cơ sở ra sao, mức độ nhập nhằng liên hệ thế nào với chất lượng, cụm từ cố định có tạo ra thay đổi đáng kể hay không, và huấn luyện chung hai chiều khác gì so với huấn luyện riêng từng chiều. Phần cuối phân loại lỗi và nêu các giới hạn của thiết lập hiện tại.

4.1 Dữ liệu

Khóa luận sử dụng ba nguồn dữ liệu do Trung tâm Ngôn ngữ học Tính toán, Trường Đại học Khoa học Tự nhiên cung cấp:

- a) Ngữ liệu song song: bao gồm các cặp câu Hán/Nôm và chuỗi chuyển tự Quốc ngữ tương ứng, được sử dụng làm dữ liệu huấn luyện chính cho mô hình.
- b) Tự điển Hán/Nôm và Quốc ngữ: bao gồm các ánh xạ ở cấp từ giữa đơn vị Hán/Nôm và cách đọc Quốc ngữ tương ứng. Nguồn này mở rộng độ bao phủ từ vựng và hỗ trợ mô hình ở những trường hợp hiếm xuất hiện trong ngữ liệu song song.

- c) Tập cụm từ cố định Hán/Nôm và Quốc ngữ: bao gồm các thành ngữ, cụm danh từ và đơn vị đa ký tự có ánh xạ tương đối ổn định. Nguồn này được dùng để khảo sát hai cách khai thác thông tin ở cấp cụm từ.

4.1.1 Tiền xử lý

Các nguồn dữ liệu do Trung tâm Ngôn ngữ học Tính toán cung cấp nên khóa luận không thực hiện thu thập hoặc gán nhãn. Trước khi huấn luyện, khóa luận chuẩn bị dữ liệu bằng các bước sau:

- Loại bỏ khoảng trắng thừa và các dấu câu không cần thiết;
- Chuẩn hóa chữ thường đối với phần Quốc ngữ;
- Loại bỏ các mục trùng lặp;
- Loại bỏ các cặp không có cùng số token ở hai phía sau khi tách token.

Sau tiền xử lý, dữ liệu song song được chia thành ba tập: huấn luyện (train), phát triển (dev) và kiểm tra (test) theo tỉ lệ 8:1:1. Quá trình chia tập được thực hiện theo nguyên tắc phân tầng theo độ dài câu: các cặp câu được nhóm vào các bin theo độ dài rồi lấy mẫu từ mỗi bin sao cho phân phối độ dài ở cả ba tập là tương đồng nhau. Từ vựng thống nhất và tập ứng viên được xây dựng từ các cặp căn chỉnh thuộc tập huấn luyện và tập phát triển, kết hợp với tự điển; tập kiểm tra được giữ tách biệt và không tham gia bước xây dựng này. Tự điển và tập cụm từ cố định không tham gia vào quá trình chia tập.

Vai trò của tập cụm từ cố định được khảo sát như một biến thực nghiệm độc lập theo ba cấu hình: (1) không sử dụng, (2) tích hợp vào từ vựng và huấn luyện cùng ngữ liệu song song, và (3) áp dụng như bước hậu xử lý sau khi giải mã: thay thế các chuỗi ký tự khớp với mục trong bảng cụm từ bằng ánh xạ tương ứng. Tự điển được dùng để mở rộng độ bao phủ tập ứng viên trong tất cả các cấu hình.

4.1.2 Quy mô dữ liệu

Loại dữ liệu	Hán	Nôm
Tổng hợp theo nguồn		
Song song	1649187	253971
Tự điển	52712	98101
Cụm từ cố định	5259	3060
Chia tập dữ liệu song song (8:1:1)		
Huấn luyện	1319350	203176
Phát triển	164918	25398
Kiểm tra	164919	25397

Bảng 4.1: Thống kê các tập dữ liệu (số lượng cặp câu).

Bên cạnh chênh lệch về số câu song song, hệ chữ Nôm còn có bộ ký tự lớn hơn hệ chữ Hán do chữ Nôm mở rộng bộ chữ Hán bằng nhiều ký tự tự tạo (Mục 2.1.2). Bộ chữ lớn hơn trong khi lượng dữ liệu song song ít hơn làm cho số ví dụ trung bình trên mỗi ánh xạ giảm. Đây là một trong các yếu tố có thể khiến các cấu hình chữ Nôm khó hơn trong thực nghiệm.

4.1.3 Tổ chức dữ liệu theo hệ chữ

Khác với công trình [15], vốn tổ chức ngữ liệu theo lĩnh vực và tập trung vào chiều Nôm $\rightarrow$ Quốc ngữ, khóa luận tách dữ liệu thành hai hệ Hán/Quốc ngữ và Nôm/Quốc ngữ, rồi khảo sát hai chiều trong từng hệ. Cách tổ chức này giữ riêng bộ ký tự, tập ứng viên và phân bố đa trị của chữ Hán và chữ Nôm; hai chiều trong cùng một hệ vẫn chia sẻ bộ mã hóa (Mục 3.4).

Việc tách theo hệ chữ không khai thác chuyển giao trực tiếp giữa chữ Hán và chữ Nôm; đây là một giới hạn của thiết lập hiện tại.

4.2 Độ đo đánh giá

Khóa luận sử dụng BLEU làm độ đo chính để so sánh các mô hình. Bên cạnh đó, độ chính xác theo vị trí được dùng để đánh giá bổ sung cho CCT-C và CCT-D, vì hai mô hình này sinh một token đích tương ứng với mỗi vị trí nguồn.

4.2.1 Điểm BLEU

Để đánh giá các mô hình chuyển tự, khóa luận dùng điểm BLEU (Bilingual Evaluation Understudy) [28]. Trong khóa luận này, BLEU đo tỉ lệ khớp của các chuỗi con liên tiếp (n-gram) giữa chuỗi chuyển tự do mô hình sinh ra và chuỗi tham chiếu, kèm theo hệ số hình phạt nếu chuỗi đầu ra quá ngắn. Khóa luận sử dụng BLEU-4, tức bậc n-gram tối đa là $N = 4$:

$$\text{BLEU} = BP \cdot \exp\left(\sum_{n=1}^N w_n \log p_n\right), \quad (4.1)$$

trong đó:

- p_n : độ chính xác n-gram hiệu chỉnh (modified n-gram precision) bậc n , trong đó số lần khớp của mỗi n-gram được chặn theo số lần xuất hiện trong bản tham chiếu;
- $w_n = \frac{1}{N}$: trọng số đều nhau cho mỗi bậc n-gram;
- $N = 4$: bậc n-gram tối đa được sử dụng trong toàn bộ thực nghiệm;
- BP : hệ số hình phạt độ ngắn:

$$BP = \begin{cases} 1 & \text{nếu } c > r, \\ e^{(1-r/c)} & \text{nếu } c \leq r, \end{cases} \quad (4.2)$$

với c là độ dài chuỗi chuyển tự do mô hình sinh ra và r là độ dài chuỗi tham chiếu.

Các cặp tham chiếu trong bộ dữ liệu có cùng số token ở hai phía sau bước tiền xử lý. Tuy nhiên, độ dài giả thuyết do mô hình sinh ra vẫn được tính riêng; nếu giả thuyết ngắn hơn tham chiếu thì thành phần BP sẽ làm giảm điểm. Điểm BLEU được biểu diễn trên thang từ 0 đến 100, trong đó giá trị cao hơn cho biết mức trùng khớp n-gram với bản tham chiếu lớn hơn.

Điểm BLEU trong khóa luận được tính ở mức âm tiết và ký tự, trong đó mỗi đơn vị đầu ra, một âm tiết tiếng Việt hoặc một ký tự Hán/Nôm, được tách thành một token riêng. BLEU tổng hợp độ chính xác n-gram có cắt ngưỡng cùng hình phạt độ dài; do đó, độ đo này phản ánh mức trùng khớp của các chuỗi con liên tiếp với bản tham chiếu, nhưng không đồng nhất với tỉ lệ token đúng tại từng vị trí.

4.2.2 Độ chính xác theo vị trí

Hai phương pháp CCT khai thác quan hệ căn chỉnh gần một đối một giữa chuỗi nguồn và chuỗi đích, trong đó mỗi vị trí nguồn tương ứng với một token đích. Vì vậy, độ chính xác theo vị trí (token accuracy) được dùng để đo trực tiếp tỉ lệ token được dự đoán đúng.

Độ chính xác theo vị trí được tính bằng tỉ lệ giữa tổng số token được dự đoán đúng và tổng số token trong toàn bộ tập kiểm tra:

$$\text{Acc}_{\text{token}} = \frac{N_{\text{correct}}}{N_{\text{total}}} \times 100, \quad (4.3)$$

trong đó N_{correct} là tổng số token được dự đoán đúng và N_{total} là tổng số token trong tập kiểm tra. Giá trị của độ đo nằm trong khoảng từ 0 đến 100, trong đó giá trị càng cao cho thấy mô hình dự đoán đúng tại càng nhiều vị trí.

Độ chính xác theo vị trí chỉ phù hợp khi chuỗi dự đoán và chuỗi tham

chiều có cùng số token. Điều kiện này được bảo đảm trong CCT-C và CCT-D, vì mỗi vị trí nguồn chỉ sinh một token đích từ tập ứng viên tương ứng (Mục 3.2.1). Mô hình Transformer cơ sở có thể sinh chuỗi khác độ dài tham chiếu nên không được đối chiếu bằng độ đo này.

4.3 Thiết lập thực nghiệm

4.3.1 Mô hình so sánh

Khóa luận so sánh ba mô hình chính. Đối với hai phương pháp CCT, ảnh hưởng của cụm từ cố định được khảo sát theo ba cấu hình (không dùng, hậu xử lý, tích hợp), trình bày chi tiết ở Mục 4.4.3:

- Transformer (cơ sở): mô hình Transformer bộ mã hóa và bộ giải mã tiêu chuẩn, huấn luyện bằng fairseq [29] trên chính tập dữ liệu thực nghiệm của khóa luận, dùng làm mô hình cơ sở so sánh. NMT cũng đã được khảo sát trong những công trình trước đây về chuyển tự chữ Nôm sang Quốc ngữ [2], [14], nhưng các công trình này không nhất thiết sử dụng cùng kiến trúc, bộ dữ liệu hoặc cách chia tập. Quy mô kiến trúc được giữ tương đương với các mô hình CCT và suy luận dùng cùng kích thước chùm tia với CCT-D; thiết lập chi tiết được đối chiếu trong Bảng 4.3.
- CCT-C: phương pháp thứ nhất, phân loại cục bộ tại từng vị trí và giải mã song song (Mục 3.5).
- CCT-D: phương pháp thứ hai, bổ sung bộ giải mã Transformer có ràng buộc ứng viên, giải mã tự hồi quy bằng tìm kiếm chùm tia (Mục 3.6).

Các công trình được tổng hợp tại Mục 2.4 không chỉ khác nhau về kiến trúc mô hình mà còn sử dụng các nguồn dữ liệu bổ sung và quy trình xử lý riêng. Trong hướng SMT, ngữ liệu Quốc ngữ đơn ngữ được dùng để huấn

luyện mô hình ngôn ngữ và các ánh xạ trong tự điển giữa chữ Hán/Nôm và Quốc ngữ được bổ sung vào bảng cụm từ [10]. Nghiên cứu tiếp theo sử dụng thêm ngữ liệu song song giữa chữ Hán và âm Hán Việt, cùng tự điển Hán Việt, để hỗ trợ chuyển tự Nôm sang Quốc ngữ [15]. Trong hướng NMT đa ngôn ngữ, dữ liệu tiếng Anh và tiếng Hoa được bổ sung cho dữ liệu Nôm và Quốc ngữ [1]. Phương pháp dựa trên T5 sử dụng trọng số huấn luyện sẵn và dữ liệu song song Hán và Quốc ngữ được xây dựng thêm từ thơ chữ Hán, trong đó một phần phía Quốc ngữ được tạo tự động [16].

Do đó, chỉ thay thế tập dữ liệu của khóa luận trong các cài đặt của những công trình này là chưa đủ để tái hiện trung thực các phương pháp đã công bố. Ngược lại, nếu giữ nguyên các nguồn dữ liệu bổ sung và quy trình ban đầu thì các mô hình sẽ không còn được đánh giá trong cùng điều kiện thực nghiệm, khiến kết quả chịu ảnh hưởng đồng thời của nhiều yếu tố ngoài kiến trúc mô hình. Vì vậy, khóa luận lựa chọn Transformer cơ sở được huấn luyện và đánh giá trên cùng cách chia dữ liệu và cùng quy trình tiền xử lý để làm đối chứng. Trong phạm vi phù hợp với từng kiến trúc, quy mô mô hình cùng các thiết lập huấn luyện và suy luận được giữ tương đương giữa Transformer cơ sở, CCT-C và CCT-D. Cách tổ chức này giúp giảm ảnh hưởng của các yếu tố ngoài phương pháp đề xuất, từ đó tạo cơ sở nhất quán để đánh giá CCT-C và CCT-D.

Việc lựa chọn mô hình cơ sở xuất phát từ vai trò của nó trong thực nghiệm. Mô hình cơ sở ở đây không nhằm đại diện cho kết quả tốt nhất từng được công bố trên bài toán chuyển tự, mà nhằm trả lời một câu hỏi hẹp hơn: với cùng dữ liệu, cùng cách chia tập và cùng quy mô kiến trúc, một mô hình sinh chuỗi không có ràng buộc tập ứng viên đạt kết quả ra sao. Kiến trúc Transformer mã hóa và giải mã phù hợp với vai trò này vì ba lý do. Thứ nhất, đây là kiến trúc nền của các công trình nơ ron gần đây trên bài toán chuyển tự Hán/Nôm [2], [14], [16], nên nó đại diện cho hướng tiếp cận đang phổ biến. Thứ hai, hai mô hình CCT cũng được xây dựng trên cùng họ kiến trúc, nên khi giữ nguyên quy mô và dữ liệu thì khác biệt còn lại tập trung vào cách xác định không gian đầu ra. Thứ ba,

mô hình được huấn luyện từ đầu nên không mang theo tri thức từ ngữ liệu bên ngoài.

Hướng dịch máy thống kê không được chọn làm đối chứng vì hai lý do. Hệ thống loại này cần thêm ngữ liệu đơn ngữ để huấn luyện mô hình ngôn ngữ và cần tự điển được đưa vào bảng cụm từ [10], [15], nên không thể tái hiện chỉ bằng ngữ liệu song song của khóa luận. Quan trọng hơn, bảng cụm từ đã mang sẵn một dạng giới hạn phương án đầu ra, nên hệ thống này không đóng được vai trò đối chứng cho trường hợp không có ràng buộc.

Phương pháp dựa trên trọng số huấn luyện sẵn [16] không được chọn vì một lý do khác. Mô hình được sử dụng trong công trình này đã được tiền huấn luyện trên văn xuôi tiếng Việt hiện đại, văn học cổ điển và các trích đoạn song song giữa Quốc ngữ và Hán/Nôm, rồi mới được tinh chỉnh riêng cho từng hệ chữ. Những nguồn tiền huấn luyện đó có thể trùng với các văn bản trong ngữ liệu song song của khóa luận, nên khi đánh giá trên tập kiểm tra sẽ không tách được phần chất lượng đến từ phương pháp khởi phần đến từ tri thức mà mô hình đã tiếp nhận trước đó. Ngoài ra, so sánh một mô hình tinh chỉnh từ trọng số sẵn với các mô hình huấn luyện từ đầu sẽ đưa thêm yếu tố tiền huấn luyện vào phép đối chiếu, trong khi yếu tố này nằm ngoài phạm vi khảo sát của khóa luận.

4.3.2 Cấu hình mô hình

Hai mô hình CCT dùng kiến trúc bộ mã hóa BERT huấn luyện từ đầu (không dùng trọng số huấn luyện sẵn), với các siêu tham số được trình bày trong Bảng 4.2. Cấu hình bộ mã hóa dùng chung cho cả CCT-C và CCT-D; CCT-D bổ sung thêm bộ giải mã với siêu tham số riêng.

Siêu tham số	Giá trị
Bộ mã hóa (dùng chung CCT-C và CCT-D)	
Kích thước ẩn (d_{model})	256
Số lớp bộ mã hóa (L)	6
Số đầu chú ý	8
Kích thước FFN (d_{ff})	1024
Độ dài chuỗi tối đa	128 token (gồm token chỉ thị chiều)
Bộ giải mã (chỉ CCT-D)	
Số lớp bộ giải mã (N_d)	6
Số đầu chú ý bộ giải mã	8
Kích thước ẩn bộ giải mã	256
Kích thước FFN bộ giải mã	1024
Dropout bộ giải mã	0.1

Bảng 4.2: Cấu hình hai mô hình CCT.

Mô hình Transformer cơ sở (Mục 4.3.1) dùng cùng các giá trị quy mô trong Bảng 4.2 cho cả bộ mã hóa lẫn bộ giải mã, đồng thời chia sẻ toàn bộ bảng nhúng giữa nguồn và đích.

4.3.3 Cấu hình huấn luyện

Bảng 4.3 đối chiếu thiết lập huấn luyện và suy luận của hai phương pháp CCT với mô hình Transformer cơ sở. Các mô hình được huấn luyện trên cùng tập dữ liệu và phần cứng.

Thiết lập	CCT-C / CCT-D	Transformer cơ sở
Bộ tối ưu hóa	AdamW [30]	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.98$)
Tốc độ học	5×10^{-4}	5×10^{-4}
Hệ số suy giảm trọng số	0.01	10^{-4}
Giai đoạn khởi động	5% tổng số bước	1000 bước
Lịch tốc độ học	Suy giảm cosin	Nghịch đảo căn bậc hai
Tỉ lệ loại bỏ (dropout)	0.1	0.3
Hệ số làm trơn nhân	Không	0.1
Cách tạo lô dữ liệu	64 câu	4096 token tích lũy gradient 4 bước
Số vòng huấn luyện tối đa	30	50
Ngưỡng chờ dừng sớm	5 lần đánh giá	5 lần đánh giá
Ngưỡng cắt gradient	1.0	Không
Độ chính xác số thực	BF16	FP16
Kích thước chùm tia	Không dùng (CCT-C) 5 (CCT-D)	5
Phần cứng	Google Colab A100 (40 GB)	

Bảng 4.3: Thiết lập huấn luyện của hai phương pháp CCT và mô hình Transformer cơ sở.

Dù dùng cùng dữ liệu, phần cứng và quy mô kiến trúc gần tương đương, hai nhóm mô hình có công thức huấn luyện khác nhau do được triển khai trên hai khung phần mềm riêng. Vì vậy, kết quả sau đây so sánh các hệ thống theo toàn bộ thiết lập đã báo cáo, không phải một thí nghiệm kiểm soát chỉ thay đổi riêng kiến trúc.

4.4 Kết quả

4.4.1 So sánh tổng thể

Bảng 4.4 trình bày kết quả so sánh ba mô hình trên tập kiểm tra, đánh giá theo điểm BLEU trên cả hai chiều chuyển tự và cả hai hệ chữ (Hán và Nôm). Bảng sử dụng cấu hình không có cụm từ cố định nhằm loại ảnh hưởng của thành phần này khi so sánh các hệ thống. Kết quả đầy đủ với các cấu hình cụm từ cố định được trình bày tại Mục 4.4.3.

Mô hình	Hán		Nôm	
	vi2no	no2vi	vi2no	no2vi
Transformer (cơ sở)	87.65	98.62	40.11	69.22
CCT-C	88.16 (+0.51)	99.33 (+0.71)	53.24 (+13.13)	68.04 (−1.18)
CCT-D	91.14 (+3.49)	99.28 (+0.66)	54.66 (+14.55)	71.92 (+2.70)

Bảng 4.4: Kết quả so sánh các mô hình trên tập kiểm tra (điểm BLEU).

Giá trị trong ngoặc là mức chênh lệch BLEU so với mô hình Transformer cơ sở trong cùng cột; giá trị cao nhất của mỗi cột được in đậm.

Ngoài điểm BLEU, độ chính xác theo vị trí được sử dụng để đánh giá trực tiếp tỉ lệ token được dự đoán đúng của hai mô hình CCT. Kết quả được trình bày trong Bảng 4.5.

Mô hình	Hán		Nôm	
	vi2no	no2vi	vi2no	no2vi
CCT-C	94.32	99.68	72.88	82.17
CCT-D	95.67	99.66	73.35	84.41

Bảng 4.5: Độ chính xác theo vị trí của hai mô hình CCT trên tập kiểm tra (%).

Kết quả độ chính xác theo vị trí cho thấy CCT-D cao hơn CCT-C ở ba trong bốn cấu hình. Chênh lệch lớn nhất là 2.24 điểm phần trăm ở chiều no2vi chữ Nôm. Riêng chiều no2vi chữ Hán, CCT-C cao hơn CCT-D 0.02 điểm phần trăm. Xu hướng này phù hợp với kết quả BLEU khi CCT-D cũng đạt kết quả cao nhất ở ba cấu hình, còn CCT-C đạt kết quả cao nhất ở chiều no2vi chữ Hán.

CCT-D đạt điểm BLEU cao hơn mô hình Transformer cơ sở trên cả bốn cấu hình, với mức chênh lệch lớn nhất ở chiều vi2no chữ Nôm (+14.55 BLEU). CCT-C đạt điểm cao hơn mô hình cơ sở trên ba cấu hình, ngoại trừ chiều no2vi chữ Nôm. Ở chiều no2vi chữ Hán, CCT-C đạt điểm cao nhất (99.33), cao hơn CCT-D 0.05 BLEU. Một cách giải thích khả dĩ liên quan đến phân bố tập ứng viên: chiều no2vi chữ Hán có trung bình khoảng

1.5 ứng viên mỗi vị trí, thấp nhất trong bốn cấu hình (Bảng 3.2). Khi mức độ nhập nhằng thấp, biểu diễn ngữ cảnh nguồn của CCT-C có thể đã cung cấp đủ thông tin để lựa chọn ứng viên, nên bộ giải mã tự hồi quy của CCT-D không tạo ra lợi thế rõ rệt. Bên cạnh đó, CCT-D có thể chịu ảnh hưởng của thiên lệch phối nhiễm giữa pha huấn luyện và suy luận. Tuy nhiên, cần thêm thực nghiệm có kiểm soát để xác định riêng ảnh hưởng của từng yếu tố.

Hai phương pháp khác nhau chủ yếu ở cách sử dụng ngữ cảnh đích. CCT-C đưa ra dự đoán riêng tại từng vị trí dựa trên biểu diễn ngữ cảnh nguồn h_i , không điều kiện hóa trực tiếp theo các token đích đã sinh trước đó. Trong khi đó, CCT-D sử dụng bộ giải mã Transformer tự hồi quy: tại bước t , mô hình kết hợp các token đích trước $(y_1, \dots, y_{t-1})$ thông qua cơ chế tự chú ý có mặt nạ trước khi chọn ứng viên. Thiết kế này cho phép CCT-D khai thác thêm sự phụ thuộc trong chuỗi đích và có thể hữu ích ở những trường hợp đa trị cần duy trì tính nhất quán giữa các vị trí.

Liên hệ giữa độ nhập nhằng và chất lượng. Trong từng hệ chữ, chiều có nhiều ứng viên trung bình hơn cũng đạt BLEU thấp hơn: Hán vi2no có 6.8 ứng viên và đạt 91.14 BLEU, so với 1.5 ứng viên và 99.28 BLEU ở chiều no2vi; các giá trị tương ứng trên dữ liệu Nôm là 18.5/54.66 và 4.3/71.92. Tuy nhiên, khi đối chiếu giữa hai hệ chữ, quy mô dữ liệu và kích thước bộ ký tự cũng thay đổi đồng thời (Bảng 4.1). Do đó, kết quả chỉ cho thấy một mối liên hệ quan sát được, chưa đủ để xác định ảnh hưởng riêng của độ nhập nhằng.

4.4.2 Ảnh hưởng của huấn luyện chung hai chiều

Trong thiết lập chính, mỗi mô hình CCT xử lý cả hai chiều chuyển tự của một hệ chữ. Để đánh giá ảnh hưởng của thiết kế này, khóa luận so sánh với phương án huấn luyện một mô hình độc lập cho từng chiều. Hai phương án giữ nguyên kiến trúc, siêu tham số và quy trình huấn luyện.

Bảng 4.6 trình bày kết quả khi không sử dụng cụm từ cố định.

Cấu hình	CCT-C			CCT-D		
	Riêng	Chung	Δ	Riêng	Chung	Δ
Hán vi2no	85.12	88.16	+3.04	86.07	91.14	+5.07
Hán no2vi	98.51	99.33	+0.82	98.31	99.28	+0.97
Nôm vi2no	42.97	53.24	+10.27	46.91	54.66	+7.75
Nôm no2vi	60.92	68.04	+7.12	63.50	71.92	+8.42

Bảng 4.6: So sánh phương án huấn luyện chung hai chiều và huấn luyện riêng từng chiều (điểm BLEU).

Cột Δ biểu thị chênh lệch BLEU giữa phương án huấn luyện chung và huấn luyện riêng trong cùng cấu hình.

Trong các lần chạy được báo cáo, huấn luyện chung đạt BLEU cao hơn ở cả tám cấu hình so sánh. Mức cải thiện trung bình là 5.31 điểm đối với CCT-C và 5.55 điểm đối với CCT-D.

Mức cải thiện nhỏ nhất xuất hiện ở chiều Hán no2vi, đạt 0.82 điểm với CCT-C và 0.97 điểm với CCT-D. Đây cũng là cấu hình có số ứng viên trung bình thấp nhất, khoảng 1.5 ứng viên tại mỗi vị trí. Ngược lại, các cấu hình trên dữ liệu Nôm đều cải thiện trên 7 điểm BLEU; lớn nhất là 10.27 điểm với CCT-C ở chiều vi2no và 8.42 điểm với CCT-D ở chiều no2vi. Tuy nhiên, quy mô dữ liệu và mức độ đa trị cùng thay đổi giữa các cấu hình, nên chưa thể kết luận yếu tố nào là nguyên nhân chính tạo nên sự khác biệt này.

Cần lưu ý rằng mỗi cặp câu song song tạo hai mẫu huấn luyện cho mô hình chung, nhưng chỉ tạo một mẫu cho mỗi mô hình huấn luyện riêng. Do đó, thí nghiệm này chưa tách biệt được ảnh hưởng của việc chia sẻ tham số và ảnh hưởng của lượng dữ liệu huấn luyện tăng lên. Vì vậy, kết quả chỉ cho thấy thiết kế huấn luyện chung mang lại BLEU cao hơn trong cả tám cấu hình, chứ chưa xác định được mức đóng góp riêng của từng yếu tố. Về triển khai, phương án này cũng chỉ cần một mô hình cho mỗi hệ chữ thay vì hai mô hình riêng cho hai chiều chuyển tự.

4.4.3 Ảnh hưởng của cụm từ cố định

Bảng 4.7 dùng Transformer không có cụm từ cố định làm mốc tham chiếu và trình bày kết quả của CCT-C, CCT-D theo ba cấu hình: không dùng, hậu xử lý và tích hợp. Ở cấu hình hậu xử lý, sau khi mô hình giải mã chuỗi ở cấp token đơn, hệ thống đối sánh cụm từ trên chuỗi nguồn rồi ghi đè các token đầu ra tại những vị trí tương ứng bằng ánh xạ trong bảng cụm từ. Ở cấu hình tích hợp, các cụm từ được gộp vào từ vựng trước khi huấn luyện cùng ngữ liệu song song. Tự điển được dùng để mở rộng tập ứng viên trong tất cả các cấu hình của hai phương pháp CCT.

Mô hình	Cụm từ	Hán		Nôm	
		vi2no	no2vi	vi2no	no2vi
Transformer (cơ sở)	Không	87.65	98.62	40.11	69.22
CCT-C	Không	88.16	<u>99.33</u>	53.24	68.04
	Hậu xử lý	88.27	<u>99.33</u>	53.25	68.09
	Tích hợp	87.67	99.35	52.27	67.32
CCT-D	Không	<u>91.14</u>	99.28	<u>54.66</u>	<u>71.92</u>
	Hậu xử lý	91.15	99.29	54.67	71.94
	Tích hợp	90.69	99.28	54.55	71.89

Bảng 4.7: Kết quả đầy đủ các mô hình theo cấu hình cụm từ cố định (điểm BLEU).

Trong mỗi cột, kết quả cao nhất được in đậm và kết quả cao thứ hai được gạch chân; nếu có đồng hạng ở vị trí thứ hai thì tất cả giá trị đồng hạng đều được gạch chân. Transformer chỉ đóng vai trò mốc tham chiếu và không được khảo sát với hai cách khai thác cụm từ trong bảng này.

Nhận xét. Hậu xử lý chỉ làm CCT-D tăng tối đa 0.02 BLEU so với cấu hình không dùng cụm từ; mức tăng lớn nhất của CCT-C khi hậu xử lý là 0.11 BLEU. Với CCT-C, tích hợp cụm từ đạt 99.35 ở chiều Hán no2vi

nhưng làm giảm điểm ở ba cấu hình còn lại. Các chênh lệch đều nhỏ và mới được ghi nhận từ một lần chạy, nên chưa thể kết luận thành phần cụm từ tạo ra cải thiện ổn định.

4.5 Phân tích lỗi

Phần này phân tích định tính một số lỗi được quan sát trong kết quả chuyển tự trên tập kiểm tra. Các ví dụ được lựa chọn để minh họa các dạng nhầm lẫn còn tồn tại của mô hình; do chưa thống kê trên toàn bộ lỗi, phần này không kết luận về tần suất tương đối của từng dạng.

4.5.1 Các dạng nhầm lẫn được quan sát

Ở chiều *no2vi*, các trường hợp quan sát được gồm chọn một cách đọc khác, sai thanh điệu hoặc nhầm giữa cách đọc Hán Việt và cách đọc thuần Việt. Ở chiều *vi2no*, mô hình có thể chọn nhầm giữa các chữ đồng âm hoặc giữa các dị thể tự. Bảng 4.8 minh họa một số cặp nhầm theo các dạng này.

Dạng lỗi	Ví dụ phương án bị nhầm lẫn
<i>Chiều no2vi (đọc âm)</i>	
Đa âm tự (Hán)	于/於: vu → ư
Sai thanh điệu	tĩnh → tinh
Đọc Hán Việt và thuần Việt	安: an → yên
Hư từ gần nghĩa (Nôm)	cũng → cùng
<i>Chiều vi2no (viết chữ)</i>	
Chọn nhầm chữ đồng âm	因/人 (cùng đọc “nhân”)
Dị thể tự (Nôm)	馱/得 (cùng đọc “người”)

Bảng 4.8: Ví dụ các dạng nhầm lẫn được quan sát.

4.5.2 Phân tích một số nhóm lỗi chính

Lỗi đa trị. Trong các ví dụ được khảo sát ở chiều no2vi, một ký tự Nôm/Hán có nhiều cách đọc Quốc ngữ tùy ngữ cảnh. Ràng buộc ứng viên chỉ loại các đầu ra không có trong $\mathcal{C}(x_i)$; mô hình vẫn có thể chọn sai giữa các phương án còn lại. Chênh lệch BLEU tổng thể cho thấy CCT-D đạt điểm cao hơn CCT-C ở ba trong bốn cấu hình, nhưng phân tích hiện tại chưa đo riêng hiệu quả của bộ giải mã trên nhóm lỗi đa trị này.

Lỗi chọn nhầm chữ đồng âm (chiều vi2no). Một âm tiết tiếng Việt thường có nhiều ký tự Hán/Nôm trong tập ứng viên, nên một dạng lỗi được quan sát ở chiều này là chọn sai ký tự trong số các chữ cùng âm, như cặp 因/人 (“nhân”) đã nêu ở Bảng 4.8; quy mô tập ứng viên của hai chiều vi2no được thống kê ở Bảng 3.2. Ngoài ra còn quan sát được âm “dĩ” bị nhầm giữa “已” và “以”, âm “hoa” giữa “花” và “华”. Đây là các lỗi đòi hỏi ngữ nghĩa và tri thức từ vựng để phân biệt, vượt quá thông tin ngữ âm thuần túy. Một biến thể đặc thù của chữ Nôm là lỗi giữa các dị thể tự cùng ghi một từ, như cặp 𠂔/𠂔 (“người”) trong Bảng 4.8.

Lỗi ngoài từ vựng (OOV). Khi ký tự nguồn không xuất hiện trong ngữ liệu huấn luyện lẫn tự điển, tập ứng viên rỗng và hệ thống giữ nguyên ký tự gốc ở đầu ra. Một số trường hợp quan sát được liên quan đến các dị thể chữ Nôm hiếm trong các nguồn xây dựng ứng viên; phân tích hiện tại chưa định lượng tỉ lệ của nhóm lỗi này. Tự điển mở rộng tập ánh xạ so với việc chỉ dùng ngữ liệu; tuy nhiên, khóa luận chưa có thí nghiệm loại bỏ tự điển để đo riêng ảnh hưởng của nguồn này đến độ bao phủ và lỗi OOV.

4.6 Giới hạn và hướng phát triển

4.6.1 Giới hạn

Mặc dù đạt được kết quả khả quan trong thiết lập được khảo sát, họ mô hình CCT vẫn còn một số hạn chế. Thứ nhất, chất lượng chuyển tự phụ thuộc vào độ bao phủ của tập ứng viên xây dựng từ ngữ liệu song song và tự điển. Những ký tự ngoài tập ứng viên không thể được dự đoán, trong khi các lỗi căn chỉnh trong dữ liệu cũng có thể đi vào không gian dự đoán và gây nhiễu.

Thứ hai, CCT-D vẫn chịu ảnh hưởng của thiên lệch phối nhiễm do sử dụng ép giáo viên trong huấn luyện và giải mã tự hồi quy trong suy luận. Chất lượng trên dữ liệu chữ Nôm, đặc biệt ở chiều vi2no, vẫn còn hạn chế do dữ liệu song song ít và mức độ đa trị cao.

Cuối cùng, các thực nghiệm mới được thực hiện trên một lần huấn luyện cho mỗi cấu hình và chưa tách riêng ảnh hưởng của cơ chế ràng buộc tập ứng viên khỏi các khác biệt còn lại giữa hai nhóm mô hình, gồm kiến trúc bộ mã hóa, cách tách token và cách huấn luyện hai chiều. Việc đánh giá cũng chủ yếu dựa trên BLEU và độ chính xác theo vị trí, chưa sử dụng thêm các độ đo xử lý được trường hợp chuỗi dự đoán khác độ dài chuỗi tham chiếu.

4.6.2 Hướng phát triển

Từ những hạn chế trên, một số hướng nghiên cứu tiếp theo bao gồm:

- Tiền huấn luyện bộ mã hóa trên ngữ liệu Hán/Nôm và Quốc ngữ quy mô lớn trước khi tinh chỉnh cho bài toán chuyển tự.
- Mở rộng dữ liệu và tập ứng viên bằng các nguồn tự điển, ngữ liệu đơn ngữ hoặc kỹ thuật sinh dữ liệu như back-translation.

- Giảm thiên lệch phơi nhiễm của CCT-D bằng các phương pháp huấn luyện phù hợp với giải mã tự hồi quy, chẳng hạn scheduled sampling [23].
- Nghiên cứu cơ chế xây dựng tập ứng viên theo ngữ cảnh và mở rộng mô hình để xử lý các trường hợp can chỉnh nhiều đối nhiều hoặc ở mức cụm từ.

Chương 5

Kết luận

Khóa luận nghiên cứu chuyển tự hai chiều giữa chữ Hán Nôm và chữ Quốc ngữ trong khuôn khổ dịch máy. Do tác vụ chỉ xử lý quan hệ giữa tự dạng và âm đọc, chuyển tự được dùng cùng nghĩa với dịch âm. Bài toán nhằm hỗ trợ số hóa và khai thác văn bản cổ. Phương pháp xuất phát từ hai đặc điểm của dữ liệu: chuỗi nguồn và chuỗi đích căn chỉnh gần một đối một, còn các ánh xạ quan sát được của mỗi token nguồn tạo thành một tập hữu hạn. Trên cơ sở đó, tại mỗi vị trí, không gian đầu ra được giới hạn trong tập ứng viên thay cho toàn bộ từ vựng đích.

Trên cơ sở đó, khóa luận xây dựng và đánh giá họ mô hình Candidate-Constrained Transliteration với hai biến thể: CCT-C phân loại độc lập tại từng vị trí trên biểu diễn của bộ mã hóa BERT, và CCT-D bổ sung bộ giải mã Transformer có ràng buộc ứng viên để mô hình hóa sự phụ thuộc giữa các ký tự đầu ra. Cả hai dùng chung một bộ mã hóa huấn luyện từ đầu và xử lý hai chiều chuyển tự trong một mô hình thống nhất thông qua token chỉ thị chiều chuyển tự. Ngữ liệu được tổ chức lại thành hai hệ chuyển tự độc lập theo hệ chữ Hán và Nôm, kết hợp tự điển để xây dựng tập ứng viên.

Kết quả thực nghiệm ở Bảng 4.4 cho thấy CCT-D đạt điểm BLEU cao hơn mô hình Transformer cơ sở trên cả bốn cấu hình đánh giá và đạt kết quả cao nhất ở ba cấu hình. Mức chênh lệch lớn nhất là +14.55 điểm BLEU ở chiều Quốc ngữ sang Nôm; ở chiều Hán sang Quốc ngữ, cả CCT-C

và CCT-D đều đạt trên 99 điểm BLEU. Phân tích lỗi và thống kê tập ứng viên gợi ý rằng mức độ nhập nhằng và quy mô dữ liệu đều có liên hệ với chênh lệch chất lượng giữa các cấu hình. Tuy nhiên, cần thêm thực nghiệm có kiểm soát để tách riêng ảnh hưởng của từng yếu tố.

Độ chính xác theo vị trí ở Bảng 4.5 cho thấy cùng xu hướng: CCT-D cao hơn CCT-C ở ba trong bốn cấu hình, còn CCT-C cao hơn 0.02 điểm phần trăm ở chiều Hán sang Quốc ngữ.

Việc huấn luyện chung hai chiều trong một mô hình cũng đạt điểm BLEU cao hơn phương án huấn luyện riêng từng chiều ở cả tám cấu hình so sánh (Bảng 4.6), với mức chênh lệch lớn nhất trên hệ chữ Nôm. Do mô hình chung quan sát số mẫu huấn luyện gấp đôi, kết quả này chưa tách riêng ảnh hưởng của việc chia sẻ tham số khỏi ảnh hưởng của lượng dữ liệu huấn luyện.

Phạm vi kết luận còn bị giới hạn bởi độ bao phủ của tập ứng viên, giả thiết cân chỉnh một đối một và việc mỗi cấu hình mới được báo cáo từ một lần chạy. Độ chính xác theo vị trí cũng chỉ được báo cáo cho hai mô hình CCT do yêu cầu chuỗi dự đoán và chuỗi tham chiếu có cùng độ dài. Chất lượng trên hệ chữ Nôm còn chịu ảnh hưởng của lượng dữ liệu song song ít hơn. Các hướng tiếp theo ở Mục 4.6, gồm tiền huấn luyện bộ mã hóa, mở rộng ngữ liệu Nôm và xây dựng ứng viên theo ngữ cảnh, trực tiếp xuất phát từ các giới hạn này.

Danh mục công trình của tác giả

1. Tam Tong Trong, Linh Pham Van & Vinh Luong An. (2025). Application of AI in Automatically Transliterating Sino-Nôm Script into Vietnamese National Script. Kỷ yếu Hội thảo khoa học quốc gia lần 3 “Ngôn ngữ học tính toán: Công nghệ vì con người”, trang 426–439. Nhà xuất bản Tri Thức.

Tài liệu tham khảo

Tiếng Việt

- [1] Nguyễn Hồng Bửu Long, Trang Minh Chiến, Nguyễn Thế Hữu, và Đinh Điền, “Chuyển tự chữ Nôm bằng tiếp cận dịch máy mạng neural đa ngữ,” in *Kỷ yếu Hội nghị Khoa học Công nghệ Quốc gia lần thứ XIV về Nghiên cứu cơ bản và ứng dụng Công nghệ thông tin (FAIR)*, 2021, pp. 469–475. DOI: [10.15625/vap.2021.0091](https://doi.org/10.15625/vap.2021.0091).
- [2] Đinh Điền, Trang Minh Chiến, Nguyễn Thị Kim Phụng, và Nguyễn Hồng Bửu Long, “Chuyển tự tự động từ chữ Nôm sang chữ Quốc ngữ theo tiếp cận dịch máy neural,” in *Kỷ yếu Hội nghị Quốc gia lần thứ XIII về Nghiên cứu cơ bản và ứng dụng Công nghệ thông tin (FAIR)*, Nha Trang, Việt Nam: Nhà xuất bản Khoa học Tự nhiên và Công nghệ, 2020, ISBN: 978-604-9985-77-5.
- [3] Nguyễn Tài Cẩn, *Nguồn gốc và quá trình hình thành cách đọc Hán Việt*. Nhà xuất bản Đại học Quốc gia Hà Nội, 2000.
- [4] Lê Đình Khẩn, *Từ vựng gốc Hán trong tiếng Việt*. Nhà xuất bản Đà Nẵng, 2010.
- [5] Đào Duy Anh, *Chữ Nôm: Nguồn gốc, cấu tạo, diễn biến*. Nhà xuất bản Khoa học Xã hội, 1975.
- [6] Nguyễn Quang Hồng, *Tự điển chữ Nôm dẫn giải*. Nhà xuất bản Khoa học Xã hội, 2014, ISBN: 978-604-902-288-3. [Online]. Available:

https://www.nomfoundation.org/nom-tools/Tu-Dien-Chu-Nom-Dan_Giai/Introduction?uiLang=vn.

- [7] Nguyễn Khuê, *Chữ Nôm: Cơ sở và nâng cao*. Nhà xuất bản Đại học Quốc gia Thành phố Hồ Chí Minh, 2009.
- [8] Nguyễn Thị Lâm, “Từ địa phương trong văn bản Nôm,” *Tạp chí Hán Nôm*, no. 1 (80), pp. 43–47, 2007. [Online]. Available: <https://han-nom.vass.gov.vn/ngghien-cuu-van-ban/tu-dia-phuong-trong-van-ban-nom-tap-chi-han-nom-so-1-80-2007-tr-43-47-506110>.

Tiếng Anh

- [9] S. Karimi, F. Scholer, and A. Turpin, “Machine transliteration survey,” *ACM Comput. Surv.*, vol. 43, no. 3, pp. 1–46, Apr. 2011, Art. no. 17, ISSN: 0360-0300. DOI: [10.1145/1922649.1922654](https://doi.org/10.1145/1922649.1922654). [Online]. Available: <https://doi.org/10.1145/1922649.1922654>.
- [10] D. Dinh, P. Nguyen, and L. H. B. Nguyen, “Transliterating Nôm scripts into Vietnamese national scripts using statistical machine translation,” *International Journal of Advanced Computer Science and Applications*, vol. 12, no. 2, pp. 37–45, 2021. DOI: [10.14569/IJACSA.2021.0120205](https://doi.org/10.14569/IJACSA.2021.0120205). [Online]. Available: <https://doi.org/10.14569/IJACSA.2021.0120205>.
- [11] R. Grundkiewicz and K. Heafield, “Neural machine translation techniques for named entity transliteration,” in *Proceedings of the Seventh Named Entities Workshop*, N. Chen, R. E. Banchs, X. Duan, M. Zhang, and H. Li, Eds., Melbourne, Australia: Association for Computational Linguistics, Jul. 2018, pp. 89–94. DOI: [10.18653/v1/W18-2413](https://doi.org/10.18653/v1/W18-2413). [Online]. Available: <https://aclanthology.org/W18-2413/>.

- [12] Nguyễn Thị Kim Phượng, Nguyễn Hồng Bửu Long, Đinh Điền, and Lương An Vinh, “Improving transliteration system from Nôm scripts into Vietnamese national scripts using language model,” in *Kỷ yếu Hội nghị Quốc gia lần thứ XIV về Nghiên cứu cơ bản và ứng dụng Công nghệ thông tin (FAIR)*, 2021, pp. 476–482. DOI: [10.15625/va.p.2021.0092](https://doi.org/10.15625/va.p.2021.0092).
- [13] T. N. Vo, L. Nguyen, and D. Dinh, “Improving transliteration from Nôm scripts into Vietnamese national scripts using class-based language model,” in *Proceedings of the 9th International Conference on Computer Technology Applications (ICCTA)*, 2023, pp. 252–257. DOI: [10.1145/3605423.3605459](https://doi.org/10.1145/3605423.3605459).
- [14] P. Hung, L. Nguyen, and D. Dinh, “Transliterating Nom script into Vietnamese national script using multilingual neural machine translation,” in *Intelligent Systems and Data Science*, N. Thai-Nghe, T.-N. Do, and P. Haddawy, Eds., ser. Communications in Computer and Information Science, vol. 1950, Singapore: Springer Nature Singapore, 2024, pp. 133–147, ISBN: 978-981-99-7666-9. DOI: [10.1007/978-981-99-7666-9_11](https://doi.org/10.1007/978-981-99-7666-9_11). [Online]. Available: https://doi.org/10.1007/978-981-99-7666-9_11.
- [15] L. H. Thai, L. H. B. Nguyen, and D. Dinh, “Improve the automatic transliteration from Nôm scripts into Vietnamese national scripts by integrating Sino-Vietnamese knowledge into statistical machine translation,” in *Proceedings of the 4th International Conference on Information Technology and Computer Communications (ITCC)*, 2022, pp. 69–77. DOI: [10.1145/3548636.3548647](https://doi.org/10.1145/3548636.3548647).
- [16] T. Duong, S.-D. Dinh, A. Tran, T. Nguyen, M. Ngo, and L. Nguyen, “Transliteration of Vietnamese national scripts into Sino-Nom scripts using transformer-based model,” in *Computational Intelligence in Engineering Science*, N. T. Nguyen et al., Eds., ser. Communications in Computer and Information Science, vol. 2943, Cham: Springer

- Nature Switzerland, 2026, pp. 133–145, ISBN: 978-3-032-21625-0. DOI: [10.1007/978-3-032-21625-0_10](https://doi.org/10.1007/978-3-032-21625-0_10). [Online]. Available: https://doi.org/10.1007/978-3-032-21625-0_10.
- [17] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, J. Burstein, C. Doran, and T. Solorio, Eds., Minneapolis, Minnesota: Association for Computational Linguistics, Jun. 2019, pp. 4171–4186. DOI: [10.18653/v1/N19-1423](https://doi.org/10.18653/v1/N19-1423). [Online]. Available: <https://aclanthology.org/N19-1423/>.
- [18] C.-C. Tseng, J.-F. Hu, L.-Y. Chang, and H.-C. Chen, “Learning to read chinese: The roles of phonological awareness, paired–associate learning, and phonetic radical awareness,” *Reading and Writing*, vol. 36, no. 7, pp. 1769–1795, 2023. DOI: [10.1007/s11145-022-10352-9](https://doi.org/10.1007/s11145-022-10352-9).
- [19] P. Le-Hong, A. Roussanaly, T. Minh Huyen Nguyen, and M. Rossignol, “An empirical study of maximum entropy approach for part-of-speech tagging of Vietnamese texts,” in *Actes de la 17e conférence sur le Traitement Automatique des Langues Naturelles. Articles longs*, P. Langlais and M. Gagnon, Eds., Montréal, Canada: ATALA, Jul. 2010, pp. 351–362. [Online]. Available: <https://aclanthology.org/2010.jeptalnrecital-long.36/>.
- [20] A. Vaswani et al., “Attention is all you need,” in *Advances in Neural Information Processing Systems*, I. Guyon et al., Eds., vol. 30, Curran Associates, Inc., 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.

- [21] R. Xiong et al., “On layer normalization in the transformer architecture,” in *Proceedings of the 37th International Conference on Machine Learning*, H. Daumé III and A. Singh, Eds., ser. Proceedings of Machine Learning Research, vol. 119, PMLR, Jul. 2020, pp. 10 524–10 533. [Online]. Available: <https://proceedings.mlr.press/v119/xiong20b.html>.
- [22] R. J. Williams and D. Zipser, “A learning algorithm for continually running fully recurrent neural networks,” *Neural Computation*, vol. 1, no. 2, pp. 270–280, 1989. DOI: [10.1162/neco.1989.1.2.270](https://doi.org/10.1162/neco.1989.1.2.270).
- [23] S. Bengio, O. Vinyals, N. Jaitly, and N. Shazeer, “Scheduled sampling for sequence prediction with recurrent neural networks,” in *Advances in Neural Information Processing Systems 28 (NeurIPS)*, 2015, pp. 1171–1179. [Online]. Available: <https://proceedings.neurips.cc/paper/2015/hash/e995f98d56967d946471af29d7bf99f1-Abstract.html>.
- [24] A. Radford, K. Narasimhan, T. Salimans, and I. Sutskever, “Improving language understanding by generative pre-training,” OpenAI, Tech. Rep., 2018. [Online]. Available: https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf.
- [25] H. Zhang, H. Pan, and X. Li, “A mask-based model for Mandarin Chinese polyphone disambiguation,” in *Proceedings of Interspeech 2020*, 2020, pp. 1728–1732. DOI: [10.21437/Interspeech.2020-1142](https://doi.org/10.21437/Interspeech.2020-1142).
- [26] M. Tan et al., “Exploring and adapting Chinese GPT to Pinyin input method,” in *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL), Volume 1: Long Papers*, 2022, pp. 1899–1909. DOI: [10.18653/v1/2022.acl-long.133](https://doi.org/10.18653/v1/2022.acl-long.133).

- [27] R. Caruana, “Multitask learning,” *Machine Learning*, vol. 28, no. 1, pp. 41–75, 1997. DOI: [10.1023/A:1007379606734](https://doi.org/10.1023/A:1007379606734).
- [28] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “BLEU: A method for automatic evaluation of machine translation,” in *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2002, pp. 311–318. DOI: [10.3115/1073083.1073135](https://doi.org/10.3115/1073083.1073135).
- [29] M. Ott et al., “Fairseq: A fast, extensible toolkit for sequence modeling,” in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations (NAACL-HLT)*, 2019, pp. 48–53. DOI: [10.18653/v1/N19-4009](https://doi.org/10.18653/v1/N19-4009).
- [30] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019. [Online]. Available: <https://openreview.net/forum?id=Bkg6RiCqY7>.